Chapitre 9 : Variables aléatoires discrètes

Haddad Lotfi

13/04/2026

Introduction

En première année MP, nous avons étudié les variables aléatoires X associées à des probabilités P sur un univers fini Ω, et pour lequel la tribu considérée était toujours $\mathcal{P}(\Omega)$. Ceci nous a permis de définir la probabilité que la variable aléatoire X prenne ses valeurs dans une partie A, à savoir $P(X \in A)$.

En deuxième année MP, nous nous plaçons dans le cas d'un univers pas forcément fini mais au plus dénombrable, et pour une tribu $\mathcal{T}$ pouvant être différente de $\mathcal{P}(\Omega)$. Ces variables aléatoires seront dites **discrètes**. Étant donné que $P(X = x) = P(X^{-1}(\{x\}))$, il nous faudra une condition sur les images réciproques $X^{-1}(\{x\})$ de la variable aléatoire X afin de pouvoir calculer la probabilité $P(X = x)$.

En L3 nous étudierons les variables aléatoires continues, c'est-à-dire associées à des probabilités sur un univers continu (par exemple $\mathbb{R}$).

Nous travaillons désormais sur un univers Ω au plus dénombrable, constitué de tous les résultats possibles d'une expérience. Cet univers sera muni d'une tribu $\mathcal{T}$.

Dans tout ce chapitre, nous considérerons également un ensemble E.

1 Variables aléatoires discrètes

1.1 Définitions et premières propriétés

Définition 1.1 (Variable aléatoire discrète)**.** *Une **variable aléatoire discrète** définie sur Ω et à valeurs dans E est une application $X : \Omega \to E$ telle que :*

1. *L'ensemble $X(\Omega)$ est au plus dénombrable.*
2. *Pour tout $x \in X(\Omega)$, l'image réciproque*
   $(X = x) = [X = x] = X^{-1}(\{x\}) = \{\omega \in \Omega \mid X(\omega) = x\}$ *de $\{x\}$ par X est un événement.*

En particulier :

- *Lorsque $E \subset \mathbb{R}$, on dit que X est une **variable aléatoire discrète réelle**.*
- *Lorsque $E = \mathbb{R}^2$ (respectivement $\mathbb{R}^k$ avec $k \geq 2$), on dit que X est un **couple de variables aléatoires réelles** (respectivement **vecteur aléatoire réel**).*

Remarque 1.2. *1. En probabilités, on utilise la notation suivante : l'image réciproque par X d'un élément x de E est notée $[X = x]$ ou $(X = x)$. Ceci signifie*

$$[X = x] = (X = x) = X^{-1}(\{x\}) = \{\omega \in \Omega \mid X(\omega) = x\},$$

c'est-à-dire l'ensemble des éléments ω tels que $X(\omega) = x$.

2. *Pour une variable aléatoire discrète X, on notera souvent $X(\Omega) = \{x_k \mid k \in K\}$, où $K \subset \mathbb{N}$.*
3. *La définition d'une variable aléatoire ne dépend pas d'une quelconque probabilité P, mais seulement de l'espace probabilisable $(\Omega, \mathcal{T})$.*
4. *En Sup Ω est fini, ainsi $X(\Omega)$ est fini donc au plus dénombrable. En outre chaque $(X = x) = X^{-1}(\{x\})$ est également fini. Par conséquent les variables aléatoires vues en Sup sont également des variables aléatoires discrètes.*
5. *Attention ! Une application $\Omega \to E$ quelconque avec Ω fini n'est pas toujours une variable aléatoire. Il faut que chaque $[X = x]$ soit un événement !*

Proposition 1.3 (Propriétés des variables aléatoires)**.** *Soit $X : \Omega \to E$ une variable aléatoire discrète. On pose $X(\Omega) = \{x_k \mid k \in K\}$ où $K \subset \mathbb{N}$. Alors :*

1. *Pour toute partie $A \subset E$, l'image réciproque de A par X, notée $[X \in A]$, est un événement.*
2. *Pour tout $A \subset E$, pour toute suite $(A_i)_{i\in I}$ de parties de E, on a :*

$$(X \in A) = (X \in A), \quad \left(X \in \bigcup_{i\in I} A_i\right) = \bigcup_{i\in I}(X \in A_i), \quad \left(X \in \bigcap_{i\in I} A_i\right) = \bigcap_{i\in I}(X \in A_i),$$

$$(X \in Emptyset) = Emptyset, \quad (X \in E) = \Omega.$$

3. *La famille d'événements $\Big((X = x_k)\Big)_{k\in K}$ forme un système complet d'événements.*

Démonstration. Soit $X : \Omega \to E$ une variable aléatoire discrète. Par définition, $X(\Omega)$ est au plus dénombrable et pour tout $x \in E$, l'ensemble $\{X = x\} = X^{-1}(\{x\})$ appartient à la tribu $\mathcal{T}$. On note $X(\Omega) = \{x_k \mid k \in K\}$ avec $K \subset \mathbb{N}$.

1. Soit $A \subset E$ une partie quelconque. On a :

$$[X \in A] = X^{-1}(A) = \bigcup_{x\in A} X^{-1}(\{x\}) = \bigcup_{x\in A} \{X = x\}.$$

   L'ensemble A peut être quelconque, mais $X^{-1}(A)$ est une réunion (finie ou dénombrable) d'événements de la forme $\{X = x\}$ (seuls les $x \in A \cap X(\Omega)$ contribuent, car si $x \notin X(\Omega)$, alors $\{X = x\} = \varnothing$). Comme $\mathcal{T}$ est stable par réunion dénombrable, $X^{-1}(A) \in \mathcal{T}$. Ainsi $[X \in A]$ est un événement.

2. Les propriétés énoncées découlent des propriétés générales des images réciproques :
   — $[X \in \complement A] = X^{-1}(\complement A) = \complement X^{-1}(A) = \overline{[X \in A]}$.
   — $[X \in \bigcup_{i\in I} A_i] = X^{-1}\Big(\bigcup_{i\in I} A_i\Big) = \bigcup_{i\in I} X^{-1}(A_i) = \bigcup_{i\in I}[X \in A_i]$.
   — $[X \in \bigcap_{i\in I} A_i] = X^{-1}\Big(\bigcap_{i\in I} A_i\Big) = \bigcap_{i\in I} X^{-1}(A_i) = \bigcap_{i\in I}[X \in A_i]$.
   — $[X \in \varnothing] = X^{-1}(\varnothing) = \varnothing$, et $[X \in E] = X^{-1}(E) = \Omega$.

   Toutes ces égalités sont valables pour toute famille $(A_i)_{i\in I}$ (finie ou non).

3. Les événements $(X = x_k)_{k\in K}$ sont deux à deux disjoints car les x_k sont distincts. Leur réunion est :

$$\bigcup_{k\in K} \{X = x_k\} = X^{-1}(X(\Omega)) = \Omega,$$

   puisque $X(\Omega)$ est l'image de Ω. Ainsi, ils forment une partition (au plus dénombrable) de Ω, c'est-à-dire un système complet d'événements.

□

Définition 1.4 (Événements $(X \geq x)$, etc.)**.** *Soit $X : \Omega \to \mathbb{R}$ une variable aléatoire réelle. On définit alors des événements en posant :*

— $(X \geq x) = X^{-1}([x, +\infty[)$ *et* $(X > x) = X^{-1}(]x, +\infty[)$.

— $(X \leq x) = X^{-1}(]-\infty, x])$ *et* $(X < x) = X^{-1}(]-\infty, x[)$.

Proposition 1.5 (Variable aléatoire indicatrice)**.** *Soit A un événement et $\mathbf{1}_A : \Omega \to \{0, 1\}$ la fonction indicatrice ou caractéristique de A, définie par $\mathbf{1}_A(\omega) = 1$ si $\omega \in A$ et 0 sinon. Alors $\mathbf{1}_A$ est une variable aléatoire réelle discrète. On l'appelle* ***variable aléatoire indicatrice****.*

Démonstration. Soit $A \in \mathcal{T}$ un événement. On considère $\mathbf{1}_A : \Omega \to \{0, 1\}$ définie par $\mathbf{1}_A(\omega) = 1$ si $\omega \in A$, et $\mathbf{1}_A(\omega) = 0$ sinon. Puisque $\{0, 1\} \subset \mathbb{R}$, $\mathbf{1}_A$ est à valeurs réelles.

Pour montrer que $\mathbf{1}_A$ est une variable aléatoire discrète, il suffit de vérifier que pour tout $x \in \mathbb{R}$, l'ensemble $\{\mathbf{1}_A = x\}$ est un événement (ou, de façon équivalente, que l'image réciproque de tout borélien est dans $\mathcal{T}$). Distinguons les cas :

— Si $x \neq 0$ et $x \neq 1$, alors $\{\mathbf{1}_A = x\} = \varnothing \in \mathcal{T}$.

— Si $x = 1$, alors $\{\mathbf{1}_A = 1\} = A \in \mathcal{T}$.

— Si $x = 0$, alors $\{\mathbf{1}_A = 0\} = \overline{A} \in \mathcal{T}$ (car $\mathcal{T}$ est stable par complémentaire).

Ainsi, pour tout $x \in \mathbb{R}$, $\{\mathbf{1}_A = x\}$ appartient à $\mathcal{T}$. L'image de Ω par $\mathbf{1}_A$ est $\{0, 1\}$, qui est fini (donc au plus dénombrable). Par conséquent, $\mathbf{1}_A$ est bien une variable aléatoire réelle discrète. □

Proposition 1.6 (Fonction d'une variable aléatoire)**.** *Soit $X : \Omega \to E$ une variable aléatoire discrète. Considérons une fonction $f : X(\Omega) \to F$. Alors l'application $f \circ X : \Omega \to F$ définie par $(f \circ X)(\omega) = f(X(\omega))$ est une variable aléatoire discrète. On la note usuellement $f(X)$.*

Démonstration. Soit $X : \Omega \to E$ une variable aléatoire discrète. Par définition, $X(\Omega)$ est au plus dénombrable et pour tout $x \in E$, $\{X = x\} \in \mathcal{T}$. Soit $f : X(\Omega) \to F$ une fonction quelconque. Posons $Y = f \circ X : \Omega \to F$, définie par $Y(\omega) = f(X(\omega))$.

<u>Image de Y :</u> $Y(\Omega) = f(X(\Omega))$ est l'image d'un ensemble au plus dénombrable par une fonction, donc $Y(\Omega)$ est également au plus dénombrable.

<u>Événements $\{Y = y\}$:</u> Pour tout $y \in F$, on a

$$\{Y = y\} = \{\omega \in \Omega \mid f(X(\omega)) = y\} = X^{-1}\Big(f^{-1}(\{y\})\Big).$$

L'ensemble $f^{-1}(\{y\})$ est une partie de $X(\Omega)$ (éventuellement vide). Comme X est une variable aléatoire discrète, l'image réciproque de toute partie de $X(\Omega)$ est un événement. En effet, pour toute $B \subset X(\Omega)$, on a

$$X^{-1}(B) = \bigcup_{x \in B} \{X = x\},$$

qui est une réunion au plus dénombrable d'événements (car B est au plus dénombrable), donc appartient à $\mathcal{T}$. En particulier, $X^{-1}(f^{-1}(\{y\})) \in \mathcal{T}$. Ainsi, $\{Y = y\}$ est un événement pour tout $y \in F$.

Par conséquent, $Y = f(X)$ est une variable aléatoire discrète. □

Corollaire 1.7 (Si (X_1, X_2) vecteur aléatoire discret réel alors X_1 et X_2 sont des VAD réelles)**.** *Soit $X : \Omega \to \mathbb{R}^2$ un vecteur aléatoire discret réel. Notons p_1 et p_2 les projections canoniques de $\mathbb{R}^2$ dans $\mathbb{R}$, c'est-à-dire définies par $p_1(x) = x_1$ et $p_2(x) = x_2$, pour $x = (x_1, x_2)$. Notons $X_1 = p_1(X)$ et $X_2 = p_2(X)$. Alors X_1 et X_2 sont des variables aléatoires discrètes réelles définies sur Ω.*

Démonstration. Soit $X = (X_1, X_2) : \Omega \to \mathbb{R}^2$ un vecteur aléatoire discret réel. Par définition, $X(\Omega)$ est au plus dénombrable. Les projections canoniques $p_1, p_2 : \mathbb{R}^2 \to \mathbb{R}$ sont définies par $p_1(x_1, x_2) = x_1$ et $p_2(x_1, x_2) = x_2$. On a $X_1 = p_1 \circ X$ et $X_2 = p_2 \circ X$.

Puisque X est une variable aléatoire discrète et que p_1 (resp. p_2) est une fonction définie sur $X(\Omega)$ (car $X(\Omega) \subset \mathbb{R}^2$), la proposition sur la fonction d'une variable aléatoire s'applique. Ainsi $p_1(X) = X_1$ et $p_2(X) = X_2$ sont des variables aléatoires discrètes. Leurs valeurs sont réelles, donc ce sont des variables aléatoires discrètes réelles. □

Proposition 1.8 (Si X_1 et X_2 sont des VAD réelles alors (X_1, X_2) est un vecteur aléatoire discret)**.** *Soit X_1 et X_2 deux variables aléatoires discrètes réelles. Définissons $X = (X_1, X_2) : \Omega \to \mathbb{R}^2$ par $X(\omega) = (X_1(\omega), X_2(\omega))$. Alors X est un vecteur aléatoire discret réel.*

Démonstration. Soit $X_1, X_2 : \Omega \to \mathbb{R}$ deux variables aléatoires discrètes réelles définies sur le même espace probabilisé $(\Omega, \mathcal{T}, P)$. Posons $X(\omega) = (X_1(\omega), X_2(\omega))$.

<u>Caractère au plus dénombrable de l'image :</u> $X_1(\Omega)$ et $X_2(\Omega)$ sont au plus dénombrables. L'ensemble $X(\Omega)$ est contenu dans le produit cartésien $X_1(\Omega) \times X_2(\Omega)$, qui est le produit de deux ensembles au plus dénombrables, donc lui-même au plus dénombrable. Ainsi $X(\Omega)$ est au plus dénombrable.

<u>Événements $\{X = (x, y)\}$:</u> Pour tout couple $(x, y) \in \mathbb{R}^2$, on a :

$$\{X = (x, y)\} = \{\omega \in \Omega \mid X_1(\omega) = x \text{ et } X_2(\omega) = y\} = \{X_1 = x\} \cap \{X_2 = y\}.$$

Puisque X_1 et X_2 sont des variables aléatoires discrètes, les ensembles $\{X_1 = x\}$ et $\{X_2 = y\}$ appartiennent à $\mathcal{T}$. Leur intersection, comme intersection finie d'éléments de $\mathcal{T}$, est encore dans $\mathcal{T}$. Donc $\{X = (x, y)\} \in \mathcal{T}$.

Ainsi, X satisfait les deux conditions de la définition d'un vecteur aléatoire discret réel : image au plus dénombrable et préimage de tout singleton dans $\mathcal{T}$. Par conséquent, $X = (X_1, X_2)$ est un vecteur aléatoire discret réel. □

Proposition 1.9 (Min, max et combinaisons linéaires de VAD)**.** *Soit X et Y deux variables aléatoires discrètes réelles définies sur Ω.*

1. *On définit* $\min(X, Y) : \Omega \to \mathbb{R}$ *et* $\max(X, Y) : \Omega \to \mathbb{R}$ *par :*

$$\forall \omega \in \Omega, \quad \min(X, Y)(\omega) = \min\{X(\omega), Y(\omega)\}, \quad \max(X, Y)(\omega) = \max\{X(\omega), Y(\omega)\}.$$

   Alors $\min(X, Y)$ *et* $\max(X, Y)$ *sont des variables aléatoires discrètes réelles.*

2. *Pour tout $(\lambda, \mu) \in \mathbb{R}^2$, on définit $\lambda X + \mu Y$ par :*

$$\forall \omega \in \Omega, \quad (\lambda X + \mu Y)(\omega) = \lambda X(\omega) + \mu Y(\omega).$$

   Alors $\lambda X + \mu Y$ est une variable aléatoire discrète réelle.

Démonstration. Soit $X, Y : \Omega \to \mathbb{R}$ deux variables aléatoires discrètes réelles. Leurs images $X(\Omega)$ et $Y(\Omega)$ sont au plus dénombrables.

1. <u>Min et Max.</u> Montrons que $\min(X, Y)$ est une variable aléatoire discrète. Pour tout $z \in \mathbb{R}$, on a :

$$\{\min(X, Y) = z\} = \Big(\{X = z\} \cap \{Y \geq z\}\Big) \cup \Big(\{Y = z\} \cap \{X > z\}\Big).$$

   En effet, $\min(X, Y) = z$ signifie que la plus petite des deux valeurs vaut z : soit $X = z$ et $Y \geq z$, soit $Y = z$ et $X > z$ (le cas $X = Y = z$ est inclus dans la première partie). Les ensembles $\{X = z\}$ et $\{Y = z\}$ sont des événements car X et Y sont des VAD. Quant à $\{Y \geq z\}$, il s'écrit :

$$\{Y \geq z\} = \bigcup_{y \in Y(\Omega),\, y \geq z} \{Y = y\},$$

réunion au plus dénombrable d'événements, donc un événement. De même, $\{X > z\} = \bigcup_{x \in X(\Omega),\, x > z} \{X = x\}$ est un événement. Par stabilité de $\mathcal{T}$ par intersection et réunion, $\{\min(X, Y) = z\} \in \mathcal{T}$. L'image de $\min(X, Y)$ est contenue dans $X(\Omega) \cup Y(\Omega)$, donc au plus dénombrable. Ainsi $\min(X, Y)$ est une VAD. Le même raisonnement s'applique à $\max(X, Y)$ en écrivant :

$$\{\max(X, Y) = z\} = \Big(\{X = z\} \cap \{Y \leq z\}\Big) \cup \Big(\{Y = z\} \cap \{X < z\}\Big).$$

2. <u>Combinaison linéaire.</u> Soient $\lambda, \mu \in \mathbb{R}$. Posons $Z = \lambda X + \mu Y$. L'image de Z est :

$$Z(\Omega) = \{\lambda x + \mu y \mid x \in X(\Omega),\ y \in Y(\Omega)\},$$

qui est le produit de deux ensembles au plus dénombrables, donc au plus dénombrable. Pour tout $t \in \mathbb{R}$, on a :

$$\{Z = t\} = \bigcup_{x \in X(\Omega)} \Big(\{X = x\} \cap \{Y = \frac{t - \lambda x}{\mu}\}\Big)$$

lorsque $\mu \neq 0$. Si $\mu = 0$, alors $Z = \lambda X$ et $\{Z = t\} = \{X = t/\lambda\}$ (si $\lambda \neq 0$) ou bien $Z = 0$ constant (si $\lambda = 0$). Dans tous les cas, chaque ensemble $\{X = x\}$ est un événement, et $\{Y = (t - \lambda x)/\mu\}$ est également un événement (si la valeur n'appartient pas à $Y(\Omega)$, l'ensemble est vide). La réunion est au plus dénombrable (car $X(\Omega)$ l'est), donc appartient à $\mathcal{T}$. Ainsi Z est une variable aléatoire discrète réelle.

□

1.2 Loi de probabilité d'une variable aléatoire

Proposition 1.10 (Loi de probabilité d'une variable aléatoire)**.** *Soit $(\Omega, \mathcal{T}, P)$ un espace probabilisé. Soit $X : \Omega \to E$ une variable aléatoire discrète. L'ensemble $\mathcal{A} = \mathcal{P}(X(\Omega))$ est une tribu sur l'ensemble dénombrable $X(\Omega)$. On définit une application $P_X : \mathcal{A} \to [0, 1]$ par :*

$$\forall A \in \mathcal{A}, \quad P_X(A) = P(X \in A).$$

Alors cette application P_X est une probabilité sur $(X(\Omega), \mathcal{A})$.

Démonstration. Soit $X : \Omega \to E$ une variable aléatoire discrète. L'ensemble $X(\Omega)$ est au plus dénombrable. On munit $X(\Omega)$ de la tribu $\mathcal{A} = \mathcal{P}(X(\Omega))$ (tribu pleine). Définissons : $P_X : \mathcal{A} \to [0, 1]$ par $P_X(A) = P(X \in A) = P(X^{-1}(A))$.

Vérifions les axiomes d'une probabilité :

1. **Positivité :** Pour tout $A \in \mathcal{A}$, $P_X(A) = P(X^{-1}(A)) \geq 0$ car P est une probabilité.
2. **Probabilité de l'univers :** $P_X(X(\Omega)) = P(X^{-1}(X(\Omega))) = P(\Omega) = 1$.
3. **σ-additivité :** Soit $(A_n)_{n \in \mathbb{N}}$ une suite d'éléments de $\mathcal{A}$ deux à deux disjoints. Alors :

$$P_X\left(\bigcup_{n=0}^{+\infty} A_n\right) = P\left(X^{-1}\left(\bigcup_{n=0}^{+\infty} A_n\right)\right) = P\left(\bigcup_{n=0}^{+\infty} X^{-1}(A_n)\right).$$

Les ensembles $X^{-1}(A_n)$ sont deux à deux disjoints car les A_n le sont et X^{-1} est injective en termes d'ensembles disjoints. Par σ-additivité de P,

$$P\left(\bigcup_{n=0}^{+\infty} X^{-1}(A_n)\right) = \sum_{n=0}^{+\infty} P(X^{-1}(A_n)) = \sum_{n=0}^{+\infty} P_X(A_n).$$

La série converge car ses termes sont positifs et la somme totale vaut $P_X(\bigcup A_n) \leq 1$.

Ainsi, P_X est une probabilité sur $(X(\Omega), \mathcal{A})$. $\square$

Définition 1.11 (Loi de probabilité d'une VA)**.** *La probabilité P_X est appelée **loi de probabilité** de X. Deux variables aléatoires discrètes X et Y, définies sur Ω et à valeurs dans E, sont dites **équiréparties** lorsqu'elles ont même loi, c'est-à-dire $P_X = P_Y$. On notera ceci $X \sim Y$*

Proposition 1.12 (Caractérisation de la loi P_X d'une variable aléatoire X)**.** *Soit $(\Omega, \mathcal{T}, P)$ un espace probabilisé. Soit $X : \Omega \to E$ une variable aléatoire discrète. Alors la loi P_X de X est entièrement déterminée par la donnée de :*

- *$X(\Omega) = \{x_k \mid k \in K\}$, où $K \subset \mathbb{N}$.*
- *$P_X(\{x_k\}) = P(X = x_k)$, pour tout $k \in K$.*

La probabilité $P_X(\{x_k\})$ est usuellement notée $P_X(x_k)$.

Démonstration. Soit $X : \Omega \to E$ une variable aléatoire discrète. L'ensemble $X(\Omega) = \{x_k \mid k \in K\}$ (avec $K \subset \mathbb{N}$) est au plus dénombrable. La loi P_X est définie sur la tribu $\mathcal{P}(X(\Omega))$ par $P_X(A) = P(X \in A)$ pour tout $A \subset X(\Omega)$.

Soit $A \subset X(\Omega)$. Alors

$$X^{-1}(A) = \bigcup_{x_k \in A} \{X = x_k\},$$

où les $\{X = x_k\}$ sont deux à deux disjoints (car les x_k sont distincts). Par σ-additivité de P,

$$P_X(A) = P(X^{-1}(A)) = P\left(\bigcup_{x_k \in A} \{X = x_k\}\right) = \sum_{x_k \in A} P(X = x_k).$$

La série converge (tous ses termes sont positifs et sa somme est $P_X(A) \leq 1$). Ainsi, la valeur de $P_X(A)$ est entièrement déterminée par les probabilités élémentaires $P(X = x_k)$ pour $k \in K$.

Réciproquement, si l'on se donne une famille de réels $(p_k)_{k \in K}$ tels que $p_k \geq 0$ et $\sum_{k \in K} p_k = 1$, on peut définir une probabilité sur $X(\Omega)$ par $P_X(\{x_k\}) = p_k$, puis étendre à tout $A \subset X(\Omega)$ par $P_X(A) = \sum_{x_k \in A} p_k$. Cette probabilité est la loi d'une variable aléatoire discrète prenant les valeurs x_k avec les probabilités p_k.

Par conséquent, la loi P_X est entièrement caractérisée par la donnée de l'ensemble $X(\Omega)$ et des probabilités $P_X(\{x_k\}) = P(X = x_k)$. $\square$

Proposition 1.13 (Sommabilité de $(P(X = x_k))_{k \in K}$)**.** *Soit $(\Omega, \mathcal{T}, P)$ un espace probabilisé. Soit $X : \Omega \to E$ une variable aléatoire discrète. Notons $X(\Omega) = \{x_k \mid k \in K\}$ pour $K \subset \mathbb{N}$. Alors la famille $\Big(P(X = x_k)\Big)_{k \in K}$ est sommable de somme 1.*

Démonstration. Soit $X : \Omega \to E$ une variable aléatoire discrète. L'ensemble $X(\Omega) = \{x_k \mid k \in K\}$ avec $K \subset \mathbb{N}$ est au plus dénombrable. Les événements $\{X = x_k\}$ pour $k \in K$ sont deux à deux disjoints car les valeurs x_k sont distinctes. De plus, leur réunion est Ω puisque $X(\omega)$ prend toujours l'une de ces valeurs. Par σ-additivité de la probabilité P, on a :

$$P(\Omega) = P\left(\bigcup_{k \in K} \{X = x_k\}\right) = \sum_{k \in K} P(\{X = x_k\}).$$

Or $P(\Omega) = 1$ et $P(\{X = x_k\}) = P(X = x_k)$. Ainsi,

$$\sum_{k \in K} P(X = x_k) = 1.$$

La famille $(P(X = x_k))_{k \in K}$ est à termes positifs et sa somme (finie ou infinie) vaut 1 ; elle est donc sommable. $\square$

Lemme 1.14 ($\lim_{n\to+\infty} P(X \geq n) = 0$)**.** *Soit X une variable aléatoire réelle discrète sur un espace probabilisé. Alors* $\lim\limits_{n\to+\infty} P(X \geq n) = 0$.

Démonstration. Soit X une variable aléatoire réelle discrète. Les valeurs possibles de X forment un ensemble au plus dénombrable $\{x_k \mid k \in K\}$ avec $K \subset \mathbb{N}$. On a $P(X \geq n) = \sum_{x_k \geq n} P(X = x_k)$. La série $\sum_{k\in K} P(X = x_k)$ converge (sa somme vaut 1). Le reste d'une série convergente tend vers 0, c'est-à-dire :

$$\lim_{n\to+\infty} \sum_{x_k \geq n} P(X = x_k) = 0.$$

Ainsi $\lim_{n\to+\infty} P(X \geq n) = 0$. □

1.3 Fonction de répartition d'une variable aléatoire : N'est pas indiqué dans le programme

Définition 1.15 (Fonction de répartition d'une VAD)**.** *Soit $(\Omega, \mathcal{T}, P)$ un espace probabilisé au plus dénombrable. Soit $X : \Omega \to \mathbb{R}$ une variable aléatoire discrète. On appelle* ***fonction de répartition*** *de X la fonction $F_X : \mathbb{R} \to [0, 1]$, définie par*

$$\forall x \in \mathbb{R}, \quad F_X(x) = P(X \leq x).$$

Proposition 1.16 (Propriétés de la fonction de répartition)**.** *Soit $(\Omega, \mathcal{T}, P)$ un espace probabilisé au plus dénombrable. Soit $X : \Omega \to \mathbb{R}$ une variable aléatoire discrète. On note $F_X : \mathbb{R} \to [0, 1]$ la fonction de répartition de X. Alors :*

1. *$\forall x \in \mathbb{R}$, $0 \leq F_X(x) \leq 1$.*
2. *La fonction F_X est croissante sur $\mathbb{R}$.*
3. *$\lim\limits_{x\to-\infty} F_X(x) = 0$ et $\lim\limits_{x\to+\infty} F_X(x) = 1$.*
4. *La fonction F_X est continue à droite en tout point de $\mathbb{R}$.*

Plus précisément : la fonction F_X est continue sur $\mathbb{R}$, sauf en un nombre au plus dénombrable de points $(x_i)_{1\leq i\leq n}$ ou $(x_i)_{i\in\mathbb{N}}$, en lesquels F_X est seulement continue à droite :

$$\forall i, \quad \lim_{x\to x_i^-} F_X(x) < F_X(x_i) = \lim_{x\to x_i^+} F_X(x).$$

Démonstration. Soit X une variable aléatoire discrète réelle définie sur $(\Omega, \mathcal{T}, P)$. Sa fonction de répartition est $F_X(x) = P(X \leq x)$.

1. $F_X(x)$ est une probabilité, donc $0 \leq F_X(x) \leq 1$ pour tout $x \in \mathbb{R}$.
2. **Croissance :** Soient $x \leq y$. Alors $\{X \leq x\} \subset \{X \leq y\}$, donc par croissance de P, $F_X(x) = P(X \leq x) \leq P(X \leq y) = F_X(y)$.
3. **Limites aux bornes :**
   — $\lim\limits_{x\to-\infty} F_X(x) = 0$: Pour toute suite (x_n) tendant vers $-\infty$, la suite d'événements $\{X \leq x_n\}$ est décroissante (car x_n décroît) et $\bigcap_n \{X \leq x_n\} = \varnothing$ (aucun réel n'est inférieur à tous les x_n). Par le théorème de la limite monotone (décroissant), $\lim_{n\to+\infty} P(X \leq x_n) = P(\varnothing) = 0$. D'où la limite $-\infty$ est 0.
   — $\lim\limits_{x\to+\infty} F_X(x) = 1$: Pour $x_n \to +\infty$, $\{X \leq x_n\}$ est croissant et $\bigcup_n \{X \leq x_n\} = \Omega$ (tout réel $X(\omega)$ est fini). Donc $\lim_n P(X \leq x_n) = P(\Omega) = 1$.
4. **Continuité à droite :** Soit $x_0 \in \mathbb{R}$. Pour toute suite (x_n) décroissant vers x_0 (i.e. $x_n \searrow x_0$), la suite d'événements $\{X \leq x_n\}$ est décroissante et $\bigcap_n \{X \leq x_n\} = \{X \leq x_0\}$. Par le théorème de la limite monotone, $\lim_{n\to+\infty} F_X(x_n) = F_X(x_0)$. Ainsi F_X est continue à droite en tout point.

5. **Discontinuités :** Soit $x_0 \in \mathbb{R}$. Considérons la limite à gauche $\lim_{x \to x_0^-} F_X(x)$. Pour une suite (x_n) croissant vers x_0, $\{X \leq x_n\}$ est croissant et $\bigcup_n \{X \leq x_n\} = \{X < x_0\}$. Donc $\lim_{x \to x_0^-} F_X(x) = P(X < x_0)$. Le saut en x_0 est :

$$F_X(x_0) - \lim_{x \to x_0^-} F_X(x) = P(X \leq x_0) - P(X < x_0) = P(X = x_0).$$

Comme X est discrète, l'ensemble des x_0 tels que $P(X = x_0) > 0$ est au plus dénombrable (c'est l'ensemble des valeurs prises par X avec probabilité positive). En ces points, F_X a un saut égal à $P(X = x_0)$ et n'est pas continue à gauche ; ailleurs, $P(X = x_0) = 0$ et F_X est continue. En tout point, F_X est continue à droite.

□

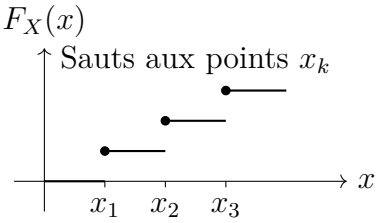

2 Couples de variables aléatoires

2.1 Lois conjointes et marginales

Définition 2.1 (Loi conjointe de deux VAD)**.** *On appelle* ***loi conjointe*** *de X_1 et X_2 la loi $P_{(X_1,X_2)}$. Cette loi est entièrement déterminée par :*

— $X(\Omega) \subset \{(x_1, x_2) \mid x_1 \in X_1(\Omega), x_2 \in X_2(\Omega)\} = X_1(\Omega) \times X_2(\Omega)$.

— *Les $P(X = (x_1, x_2)) = P((X_1 = x_1) \cap (X_2 = x_2))$, pour tous $x_1 \in X_1(\Omega)$ et $x_2 \in X_2(\Omega)$. Cette probabilité est notée $P_X(x_1, x_2)$.*

Proposition 2.2 (Lois marginales)**.** *Soit $Z = (X, Y)$ un couple aléatoire discret réel. Notons $Z(\Omega) = \{(x_i, y_j) \mid i \in I, j \in J\}$, où I et J sont deux parties au plus dénombrables de $\mathbb{N}$. Alors :*

1. *La loi de probabilité P_X de la variable aléatoire discrète réelle X est déterminée à partir de la loi $P_{(X,Y)}$ du couple (X, Y) par :*
   — $X(\Omega) = \{x_i \mid i \in I\}$.
   — $P(X = x_i) = \sum_{j \in J} P\Big((X, Y) = (x_i, y_j)\Big)$, *pour tout $i \in I$.*
2. *La loi de probabilité P_Y de la variable aléatoire discrète réelle Y est déterminée à partir de la loi $P_{(X,Y)}$ du couple (X, Y) par :*
   — $Y(\Omega) = \{y_j \mid j \in J\}$.
   — $P(Y = y_j) = \sum_{i \in I} P\Big((X, Y) = (x_i, y_j)\Big)$, *pour tout $j \in J$.*

Démonstration. Soit $Z = (X, Y)$ un couple aléatoire discret réel. L'image $Z(\Omega) = \{(x_i, y_j) \mid i \in I,\ j \in J\}$ est au plus dénombrable, où I et J sont des parties de $\mathbb{N}$ (éventuellement finies). Par définition, la loi de Z est donnée par les probabilités $P((X, Y) = (x_i, y_j)) = P(X = x_i \text{ et } Y = y_j)$.

1. <u>Loi de X :</u> L'ensemble des valeurs prises par X est $\{x_i \mid i \in I\}$. Pour un i fixé, l'événement $\{X = x_i\}$ est la réunion (disjointe) sur $j \in J$ des événements $\{X = x_i \text{ et } Y = y_j\}$, car Y prend nécessairement l'une des valeurs y_j. En effet :

$$\{X = x_i\} = \bigcup_{j \in J} \Big(\{X = x_i\} \cap \{Y = y_j\}\Big) = \bigcup_{j \in J} \{(X, Y) = (x_i, y_j)\}.$$

   Les événements $\{(X, Y) = (x_i, y_j)\}$ sont deux à deux disjoints pour j distinct (car les y_j sont distincts). Par σ-additivité de P,

$$P(X = x_i) = P\left(\bigcup_{j \in J} \{(X, Y) = (x_i, y_j)\}\right) = \sum_{j \in J} P\Big((X, Y) = (x_i, y_j)\Big).$$

   Ainsi P_X est entièrement déterminée par la loi jointe $P_{(X,Y)}$.

2. <u>Loi de Y :</u> Symétriquement, pour j fixé,

$$\{Y = y_j\} = \bigcup_{i \in I} \{(X, Y) = (x_i, y_j)\},$$

   réunion disjointe. Donc

$$P(Y = y_j) = \sum_{i \in I} P\Big((X, Y) = (x_i, y_j)\Big).$$

Ceci achève la démonstration. □

Définition 2.3 (Lois marginales d'un couple (X, Y))**.** *Les lois P_X et P_Y de X et Y sont appelées **lois marginales** du couple (X, Y).*

2.2 Variables aléatoires indépendantes

Définition 2.4 (VA indépendantes)**.** *Soit $X_1, \ldots, X_n$ n variables aléatoires discrètes réelles sur Ω. On dit qu'elles sont **indépendantes** lorsque pour tous $x_1 \in X_1(\Omega)$, …, $x_n \in X_n(\Omega)$, les événements $(X_1 = x_1), \ldots, (X_n = x_n)$ sont indépendants.*

Proposition 2.5 (Produit de lois marginales)**.** *La loi conjointe $P_{(X_1,X_2)}$ du couple $X = (X_1, X_2)$ de deux variables aléatoires indépendantes X_1 et X_2 est égale au produit des lois marginales :*

$$\forall (x_1, x_2) \in X(\Omega) = (X_1, X_2)(\Omega), \quad P_{(X_1,X_2)}(x_1, x_2) = P_{X_1}(x_1) P_{X_2}(x_2).$$

Démonstration. Soient X_1 et X_2 deux variables aléatoires discrètes réelles indépendantes définies sur le même espace probabilisé $(\Omega, \mathcal{T}, P)$. Par définition de l'indépendance de deux variables aléatoires, pour tous $x_1 \in X_1(\Omega)$ et $x_2 \in X_2(\Omega)$, on a :

$$P(X_1 = x_1 \text{ et } X_2 = x_2) = P(X_1 = x_1) \cdot P(X_2 = x_2).$$

Or, par définition de la loi conjointe $P_{(X_1,X_2)}$ du couple (X_1, X_2), on a $P_{(X_1,X_2)}(x_1, x_2) = P(X_1 = x_1 \text{ et } X_2 = x_2)$. De même, les lois marginales sont $P_{X_1}(x_1) = P(X_1 = x_1)$ et $P_{X_2}(x_2) = P(X_2 = x_2)$. Ainsi,

$$\forall (x_1, x_2) \in (X_1, X_2)(\Omega), \quad P_{(X_1,X_2)}(x_1, x_2) = P_{X_1}(x_1)\, P_{X_2}(x_2).$$

C'est exactement l'égalité annoncée. □

Exemple 2.6. *On lance deux dés équilibrés à six faces. Soit X le résultat du premier dé et Y celui du second dé. Les deux lancers sont indépendants. Alors, pour tout $(i,j) \in \{1,\dots,6\}^2$,*

$$P_{(X,Y)}(i,j) = P(X=i,\ Y=j) = P(X=i)\,P(Y=j) = \frac{1}{6}\cdot\frac{1}{6} = \frac{1}{36}.$$

Ainsi la loi conjointe est le produit des lois marginales.

On peut également construire un exemple avec un univers dénombrable infini. Soit $\Omega = \mathbb{N}^2$ muni de la probabilité $P(\{(i,j)\}) = \frac{1}{2^{i+j}}$. Cette somme sur tous les couples vaut 1. On définit $X(i,j) = i$ et $Y(i,j) = j$. Alors pour tout $(i,j) \in \mathbb{N}^2$,

$$P(X=i,\ Y=j) = \frac{1}{2^{i+j}} = \frac{1}{2^i}\cdot\frac{1}{2^j} = P(X=i)\,P(Y=j).$$

Les variables X et Y sont indépendantes et leur loi conjointe est le produit des lois marginales.

3 Espérance

3.1 Définitions et premières propriétés

Définition 3.1 (Espérance d'une variable aléatoire discrète)**.** *Soit X une variable aléatoire réelle. On dit que X est **d'espérance finie** lorsque la famille $\big(xP(X=x)\big)_{x\in X(\Omega)}$ est sommable. Sa somme*

$$E(X) = \sum_{x\in X(\Omega)} xP(X=x)$$

*est appelée **espérance** de X. Lorsque la famille $\big(xP(X=x)\big)_{x\in X(\Omega)}$ n'est pas sommable (mais quand même à termes positifs), on dit parfois que X admet une espérance infinie.*

Proposition 3.2 (Espérance d'une variable aléatoire indicatrice)**.** *Soit $\mathbf{1}_A$ la variable aléatoire indicatrice de l'événement A. Alors $\mathbf{1}_A$ admet une espérance et $E(\mathbf{1}_A) = P(A)$.*

Démonstration. Soit $\mathbf{1}_A$ la variable aléatoire indicatrice de l'événement A. Elle prend la valeur 1 si $\omega \in A$ et 0 sinon. Son espérance est définie par

$$E(\mathbf{1}_A) = \sum_{x\in\mathbf{1}_A(\Omega)} x\cdot P(\mathbf{1}_A = x).$$

L'image de $\mathbf{1}_A$ est $\{0,1\}$. Ainsi,

$$E(\mathbf{1}_A) = 0\cdot P(\mathbf{1}_A=0) + 1\cdot P(\mathbf{1}_A=1) = P(\mathbf{1}_A=1).$$

Or $\{\mathbf{1}_A = 1\} = A$, donc $P(\mathbf{1}_A=1) = P(A)$. Par conséquent,

$$E(\mathbf{1}_A) = P(A).$$

□

Théorème 3.3 (Théorème de transfert : Admis)**.** *Soit X une variable aléatoire discrète et f une fonction définie sur $X(\Omega)$ et à valeurs réelles. Alors la variable aléatoire $f(X)$ a une espérance finie si et seulement si la famille $\big(f(x)P(X=x)\big)_{x\in X(\Omega)}$ est sommable. Dans ce cas :*

$$E(f(X)) = \sum_{x\in X(\Omega)} f(x)P(X=x).$$

Démonstration. Soit X une variable aléatoire discrète à valeurs dans E. On note :

$X(\Omega) = \{x_i \mid i \in I\}$ où $I \subset \mathbb{N}$ est au plus dénombrable. Soit $f : X(\Omega) \to \mathbb{R}$ une fonction. La variable aléatoire $f(X)$ est discrète (par composition) et son espérance, si elle existe, est donnée par la série $\sum_{y \in f(X)(\Omega)} y\, P(f(X) = y)$.

Pour chaque $y \in f(X)(\Omega)$, on a :

$$P(f(X) = y) = \sum_{i \in I,\, f(x_i) = y} P(X = x_i),$$

car les événements $\{X = x_i\}$ forment une partition de Ω. Ainsi,

$$E(f(X)) = \sum_{y \in f(X)(\Omega)} y \sum_{i : f(x_i) = y} P(X = x_i) = \sum_{i \in I} f(x_i) P(X = x_i),$$

où la dernière égalité résulte d'une réorganisation des termes de la série double. Cette réorganisation est légitime si et seulement si la famille $(f(x_i)P(X = x_i))_{i \in I}$ est sommable, c'est-à-dire si $\sum_{i \in I} |f(x_i)| P(X = x_i) < +\infty$. Or cette condition équivaut à $E(|f(X)|) < +\infty$ (par application du même raisonnement à $|f|$), donc à l'existence de $E(f(X))$ (car l'espérance d'une variable discrète est absolument convergente). Par conséquent, $f(X)$ a une espérance finie si et seulement si la famille $(f(x)P(X = x))_{x \in X(\Omega)}$ est sommable, et dans ce cas

$$E(f(X)) = \sum_{x \in X(\Omega)} f(x) P(X = x).$$

□

Proposition 3.4 (Linéarité de l'espérance). *1. L'ensemble $\mathcal{E}$ des variables aléatoires discrètes de Ω dans $\mathbb{R}$ et d'espérance finie est un espace vectoriel.*

2. L'application espérance $E : \mathcal{E} \to \mathbb{R}$, qui associe à une variable aléatoire son espérance, est une forme linéaire.

Démonstration. Soit $\mathcal{E}$ l'ensemble des variables aléatoires discrètes réelles définies sur $(\Omega, \mathcal{T}, P)$ et admettant une espérance finie (i.e. $E(|X|) < +\infty$).

1. Montrons que $\mathcal{E}$ est un espace vectoriel.
   - La variable nulle 0 appartient à $\mathcal{E}$ car $E(0) = 0$.
   - Soit $X \in \mathcal{E}$ et $\lambda \in \mathbb{R}$. Alors λX est discrète et $|\lambda X| = |\lambda||X|$; par linéarité de la somme (à vérifier ensuite), $E(|\lambda X|) = |\lambda| E(|X|) < +\infty$, donc $\lambda X \in \mathcal{E}$.
   - Soient $X, Y \in \mathcal{E}$. Alors $X + Y$ est discrète et $|X + Y| \leq |X| + |Y|$. Par conséquent,

     $$E(|X + Y|) \leq E(|X|) + E(|Y|) < +\infty,$$

     donc $X + Y \in \mathcal{E}$. La stabilité par addition et multiplication par un scalaire est ainsi établie. Les autres axiomes d'espace vectoriel (associativité, commutativité, etc.) sont hérités des propriétés des fonctions.
2. Montrons que l'application $E : \mathcal{E} \to \mathbb{R}$ est linéaire.
   - Soit $X \in \mathcal{E}$ et $\lambda \in \mathbb{R}$. Par définition de l'espérance d'une variable discrète,

     $$E(\lambda X) = \sum_{z \in (\lambda X)(\Omega)} z\, P(\lambda X = z).$$

     Mais λX prend les valeurs λx pour $x \in X(\Omega)$ avec $P(\lambda X = \lambda x) = P(X = x)$. Donc

     $$E(\lambda X) = \sum_{x \in X(\Omega)} \lambda x\, P(X = x) = \lambda \sum_{x \in X(\Omega)} x\, P(X = x) = \lambda E(X).$$

— Soient $X, Y \in \mathcal{E}$. On note $X(\Omega) = \{x_i\}_{i\in I}$, $Y(\Omega) = \{y_j\}_{j\in J}$. Alors

$$E(X+Y) = \sum_k (x_i + y_j)\, P(X = x_i, Y = y_j)$$

en regroupant par valeurs du couple (X, Y). La somme porte sur tous les (i, j). Par sommabilité absolue (car $E(|X|)$ et $E(|Y|)$ sont finies), on peut séparer :

$$E(X+Y) = \sum_{i,j} x_i P(X = x_i, Y = y_j) + \sum_{i,j} y_j P(X = x_i, Y = y_j).$$

Or $\sum_j P(X = x_i, Y = y_j) = P(X = x_i)$ et $\sum_i P(X = x_i, Y = y_j) = P(Y = y_j)$. Ainsi,

$$E(X+Y) = \sum_i x_i P(X = x_i) + \sum_j y_j P(Y = y_j) = E(X) + E(Y).$$

L'espérance est donc une forme linéaire sur $\mathcal{E}$.

□

Proposition 3.5 (Positivité et croissance de l'espérance). *1. L'application espérance E est positive : si $X \in \mathcal{E}$ et $X(\Omega) \subset \mathbb{R}_+$, alors $E(X) \geq 0$.*

2. L'application espérance est croissante : si $(X, Y) \in \mathcal{E}^2$ et $X \leq Y$ alors $E(X) \leq E(Y)$.

Démonstration. Soit $\mathcal{E}$ l'ensemble des variables aléatoires discrètes réelles d'espérance finie.

1. **Positivité :** Soit $X \in \mathcal{E}$ telle que $X(\Omega) \subset \mathbb{R}_+$ (i.e. $X(\omega) \geq 0$ pour tout $\omega \in \Omega$). Par définition de l'espérance,
$$E(X) = \sum_{x\in X(\Omega)} x\, P(X = x).$$
Pour chaque $x \in X(\Omega)$, on a $x \geq 0$ et $P(X = x) \geq 0$. Chaque terme de la somme est donc positif ou nul. Par conséquent, la somme (qui converge absolument car $E(|X|) = E(X)$ est finie) est également positive ou nulle : $E(X) \geq 0$.
2. **Croissance :** Soient $X, Y \in \mathcal{E}$ telles que $X \leq Y$ (c'est-à-dire $X(\omega) \leq Y(\omega)$ pour tout $\omega \in \Omega$). Posons $Z = Y - X$. Alors Z est une variable aléatoire discrète (combinaison linéaire de variables discrètes) et $Z \geq 0$. De plus, $Z \in \mathcal{E}$ car $E(|Z|) \leq E(|X|) + E(|Y|) < +\infty$ (ou directement par linéarité, Z admet une espérance). Par le point précédent, $E(Z) \geq 0$. Or, par linéarité de l'espérance,
$$E(Z) = E(Y - X) = E(Y) - E(X).$$
Ainsi $E(Y) - E(X) \geq 0$, c'est-à-dire $E(X) \leq E(Y)$.

□

Proposition 3.6 (Inégalité de Markov). *Soit X une variable aléatoire discrète réelle positive admettant une espérance finie. Alors pour tout $a > 0$:*

$$P([X \geq a]) \leq \frac{E(X)}{a}.$$

Démonstration. Soit X une variable aléatoire discrète réelle positive, d'espérance finie. Pour tout $a > 0$, on a :

$$X \geq a \cdot \mathbf{1}_{[X\geq a]},$$

où $\mathbf{1}_{[X\geq a]}$ est la variable indicatrice de l'événement $\{X \geq a\}$. En effet, si $\omega \in \{X \geq a\}$, alors $X(\omega) \geq a = a \cdot 1$; si $\omega \notin \{X \geq a\}$, alors $X(\omega) \geq 0 = a \cdot 0$. Par croissance et linéarité de l'espérance, on obtient :

$$E(X) \geq a\, E\Big(\mathbf{1}_{[X\geq a]}\Big) = a\, P(X \geq a).$$

En divisant par $a > 0$, on en déduit l'inégalité de Markov :

$$P(X \geq a) \leq \frac{E(X)}{a}.$$

□

Proposition 3.7 (Espérance d'un produit de VADR indépendantes)**.** *Soit X et Y deux variables aléatoires discrètes réelles. On suppose que X et Y sont indépendantes et admettent chacune une espérance finie. Alors la variable aléatoire XY admet une espérance finie et :*

$$E(XY) = E(X)E(Y).$$

Démonstration. Soient X et Y deux variables aléatoires discrètes réelles indépendantes, admettant chacune une espérance finie. Notons $X(\Omega) = \{x_i \mid i \in I\}$ et $Y(\Omega) = \{y_j \mid j \in J\}$ avec $I, J \subset \mathbb{N}$ au plus dénombrables. L'indépendance de X et Y implique que pour tous $i \in I$, $j \in J$,

$$P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j).$$

Par le théorème de transfert appliqué à la fonction $f(x, y) = xy$ et au couple (X, Y), on a :

$$E(XY) = \sum_{(i,j)\in I\times J} x_i y_j\, P(X = x_i, Y = y_j).$$

En utilisant l'indépendance,

$$E(XY) = \sum_{i\in I}\sum_{j\in J} x_i y_j\, P(X = x_i)P(Y = y_j) = \left(\sum_{i\in I} x_i P(X = x_i)\right)\left(\sum_{j\in J} y_j P(Y = y_j)\right).$$

Ces deux sommes sont respectivement $E(X)$ et $E(Y)$, qui sont finies par hypothèse. De plus, la série double converge absolument car

$$\sum_{i,j} |x_i y_j| P(X = x_i)P(Y = y_j) = E(|X|)E(|Y|) < +\infty,$$

ce qui justifie l'interversion des sommes et garantit que XY admet une espérance finie. Ainsi,

$$E(XY) = E(X)E(Y).$$

□

3.2 Moments

Définition 3.8 (Moment d'ordre m)**.** *Soit X une variable aléatoire discrète réelle et $m \in \mathbb{N}^*$. Si X^m admet une espérance finie, on dit que X admet un* ***moment d'ordre*** *m, et ce moment d'ordre m est $E(X^m)$.*

Théorème 3.9 (Inégalité de Cauchy-Schwarz)**.** *Soit X et Y deux variables aléatoires discrètes réelles admettant chacune un moment d'ordre 2. Alors XY a une espérance finie et*

$$E(XY)^2 \leq E(X^2)E(Y^2).$$

Démonstration. Soient X et Y deux variables aléatoires discrètes réelles admettant un moment d'ordre 2, c'est-à-dire $E(X^2) < +\infty$ et $E(Y^2) < +\infty$. Pour tout réel t, considérons la variable aléatoire $(X + tY)^2$. Elle est positive, donc son espérance est positive (par positivité de l'espérance) :

$$E\Big((X + tY)^2\Big) \geq 0.$$

Développons le carré et utilisons la linéarité de l'espérance (valable car $E(X^2)$, $E(Y^2)$ et $E(XY)$ sont finies ; on montrera que $E(XY)$ est bien définie) :

$$E(X^2) + 2t\,E(XY) + t^2\,E(Y^2) \geq 0, \qquad \forall t \in \mathbb{R}.$$

Il s'agit d'un trinôme du second degré en t (si $E(Y^2) > 0$; si $E(Y^2) = 0$, alors $Y = 0$ presque sûrement et l'inégalité est triviale). Pour qu'il soit toujours positif ou nul, son discriminant doit être négatif ou nul :

$$\Delta = \Big(2E(XY)\Big)^2 - 4\,E(X^2)\,E(Y^2) \leq 0.$$

Ainsi, $4\,E(XY)^2 - 4\,E(X^2)E(Y^2) \leq 0$, d'où $E(XY)^2 \leq E(X^2)E(Y^2)$.

Reste à vérifier que $E(XY)$ est bien définie (i.e. finie). Par l'inégalité de Cauchy-Schwarz dans le cas réel (ou par l'inégalité $|xy| \leq \frac{x^2+y^2}{2}$), on a $|E(XY)| \leq E(|XY|) \leq \frac{1}{2}(E(X^2) + E(Y^2)) < +\infty$, donc XY admet une espérance finie. □

Définition 3.10 (Variance)**.** *Soit X une variable aléatoire discrète réelle admettant un moment d'ordre deux. On définit alors la* ***variance*** *de X, notée $V(X)$, par :*

$$V(X) = E\Big((X - E(X))^2\Big)$$

*et l'****écart-type*** *de X par $\sigma(X) = \sqrt{V(X)}$.*

Proposition 3.11 (Formule de König-Huygens)**.** *Soit X une variable aléatoire discrète réelle admettant un moment d'ordre deux. Alors :*

1. *$V(X) = E(X^2) - E(X)^2$.*
2. *Pour tous réels a et b, $\sigma(aX + b) = |a|\sigma(X)$ et $V(aX + b) = a^2V(X)$.*

Démonstration. Soit X une variable aléatoire discrète réelle admettant un moment d'ordre deux, c'est-à-dire $E(X^2) < +\infty$. On note $\mu = E(X)$.

1. Par définition de la variance, $V(X) = E\Big((X - \mu)^2\Big)$. Développons le carré :

   $$(X - \mu)^2 = X^2 - 2\mu X + \mu^2.$$

   Par linéarité de l'espérance (et car $E(X^2)$ est finie),

   $$V(X) = E(X^2) - 2\mu E(X) + \mu^2 = E(X^2) - 2\mu^2 + \mu^2 = E(X^2) - \mu^2.$$

   Ainsi $V(X) = E(X^2) - E(X)^2$.
2. Soient $a, b \in \mathbb{R}$. Considérons $Y = aX + b$. Alors $E(Y) = aE(X) + b$ (par linéarité). Calculons la variance de Y :

   $$V(Y) = E\Big((Y - E(Y))^2\Big) = E\Big((aX + b - a\mu - b)^2\Big) = E\Big((a(X - \mu))^2\Big) = a^2E\Big((X - \mu)^2\Big) = a^2V(X).$$

   Pour l'écart-type $\sigma(Y) = \sqrt{V(Y)} = \sqrt{a^2V(X)} = |a|\sqrt{V(X)} = |a|\sigma(X)$.

□

Théorème 3.12 (Inégalité de Bienaymé-Tchebychev)**.** *Soit X une variable aléatoire discrète réelle admettant un moment d'ordre deux. Alors :*

$$\forall \varepsilon > 0, \quad P(|X - E(X)| \geq \varepsilon) \leq \frac{V(X)}{\varepsilon^2}.$$

Démonstration. Soit X une variable aléatoire discrète réelle admettant un moment d'ordre deux, c'est-à-dire $E(X^2) < +\infty$. Posons $\mu = E(X)$ et $\sigma^2 = V(X) = E((X-\mu)^2)$. Pour tout $\varepsilon > 0$, considérons l'événement $[|X - \mu| \geq \varepsilon]$. Celui-ci est identique à $[(X-\mu)^2 \geq \varepsilon^2]$. La variable aléatoire $(X-\mu)^2$ est positive. Appliquons l'inégalité de Markov à cette variable positive (valable car elle admet une espérance finie) :

$$P\Big((X-\mu)^2 \geq \varepsilon^2\Big) \leq \frac{E\Big((X-\mu)^2\Big)}{\varepsilon^2}.$$

Or $E\Big((X-\mu)^2\Big) = V(X)$ et $P\Big((X-\mu)^2 \geq \varepsilon^2\Big) = P(|X-\mu| \geq \varepsilon)$. On obtient donc :

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{V(X)}{\varepsilon^2}.$$

□

3.3 Covariance

Définition 3.13 (Covariance)**.** *Soit X et Y deux variables aléatoires discrètes réelles admettant un moment d'ordre 2. On appelle* ***covariance*** *de X et Y le nombre réel*

$$\operatorname{cov}(X,Y) = E\Big((X - E(X))(Y - E(Y))\Big).$$

Proposition 3.14. *Soit X et Y deux variables aléatoires discrètes réelles admettant un moment d'ordre deux. Alors la covariance de X et Y existe et on a :*

$$\operatorname{cov}(X,Y) = E(XY) - E(X)E(Y).$$

Démonstration. Soient X et Y deux variables aléatoires discrètes réelles admettant un moment d'ordre deux, c'est-à-dire $E(X^2) < +\infty$ et $E(Y^2) < +\infty$. Par l'inégalité de Cauchy-Schwarz (ou l'inégalité $|xy| \leq \frac{x^2+y^2}{2}$), on a $E(|XY|) \leq \frac{1}{2}(E(X^2) + E(Y^2)) < +\infty$. Ainsi XY admet une espérance finie, et la covariance $\operatorname{cov}(X,Y) = E\Big((X - E(X))(Y - E(Y))\Big)$ est bien définie.

Développons le produit :

$$(X - E(X))(Y - E(Y)) = XY - X\,E(Y) - Y\,E(X) + E(X)E(Y).$$

Par linéarité de l'espérance,

$$\operatorname{cov}(X,Y) = E(XY) - E(X)E(Y) - E(Y)E(X) + E(X)E(Y) = E(XY) - E(X)E(Y).$$

Ainsi $\operatorname{cov}(X,Y) = E(XY) - E(X)E(Y)$. □

Proposition 3.15 (Propriétés de la covariance)**.** *Soit X, X', Y, Y' quatre variables aléatoires discrètes réelles admettant un moment d'ordre deux. Fixons a, b, c, d quatre réels. Alors :*

1. $\operatorname{cov}(Y,X) = \operatorname{cov}(X,Y)$.
2. $\operatorname{cov}(X,X) = V(X)$.
3. $\operatorname{cov}(aX + b, cY + d) = ac \operatorname{cov}(X,Y)$.

4. $\operatorname{cov}(aX+bX', cY+dY') = ac\operatorname{cov}(X,Y)+bc\operatorname{cov}(X',Y)+ad\operatorname{cov}(X,Y')+bd\operatorname{cov}(X',Y')$.

Démonstration. On rappelle que $\operatorname{cov}(X,Y) = E(XY) - E(X)E(Y)$, valable pour des variables admettant un moment d'ordre deux.

1. **Symétrie :** $\operatorname{cov}(Y,X) = E(YX) - E(Y)E(X) = E(XY) - E(X)E(Y) = \operatorname{cov}(X,Y)$.
2. **Lien avec la variance :** $\operatorname{cov}(X,X) = E(XX) - E(X)E(X) = E(X^2) - E(X)^2 = V(X)$.
3. **Invariance par translation et homogénéité :** Soient $a,b,c,d \in \mathbb{R}$. Alors

$$\begin{aligned}
\operatorname{cov}(aX+b, cY+d) &= E\Big((aX+b)(cY+d)\Big) - E(aX+b)\,E(cY+d) \\
&= E(acXY + adX + bcY + bd) - (aE(X)+b)(cE(Y)+d) \\
&= acE(XY) + adE(X) + bcE(Y) + bd \\
&\qquad - \Big(acE(X)E(Y) + adE(X) + bcE(Y) + bd\Big) \\
&= ac\Big(E(XY) - E(X)E(Y)\Big) \\
&= ac\operatorname{cov}(X,Y).
\end{aligned}$$

4. **Bilinéarité :** On utilise la linéarité de l'espérance et la propriété précédente. D'abord,

$$\operatorname{cov}(aX+bX', cY+dY') = ac\operatorname{cov}(X,Y)+ad\operatorname{cov}(X,Y')+bc\operatorname{cov}(X',Y)+bd\operatorname{cov}(X',Y').$$

Pour le démontrer, développons :

$$\begin{aligned}
\operatorname{cov}(aX+bX', cY+dY') &= E\Big((aX+bX')(cY+dY')\Big) - E(aX+bX')E(cY+dY') \\
&= E(acXY + adXY' + bcX'Y + bdX'Y') \\
&\quad - \Big(aE(X)+bE(X')\Big)\Big(cE(Y)+dE(Y')\Big) \\
&= acE(XY) + adE(XY') + bcE(X'Y) + bdE(X'Y') \\
&\quad - acE(X)E(Y) - adE(X)E(Y') - bcE(X')E(Y) - bdE(X')E(Y') \\
&= ac\Big(E(XY) - E(X)E(Y)\Big) + ad\Big(E(XY') - E(X)E(Y')\Big) \\
&\quad + bc\Big(E(X'Y) - E(X')E(Y)\Big) + bd\Big(E(X'Y') - E(X')E(Y')\Big) \\
&= ac\operatorname{cov}(X,Y) + ad\operatorname{cov}(X,Y') + bc\operatorname{cov}(X',Y) + bd\operatorname{cov}(X',Y').
\end{aligned}$$

Ceci achève la démonstration.

□

Proposition 3.16 (Deux variables aléatoires indépendantes sont de covariance nulle)**.** *Soit X et Y deux variables aléatoires discrètes réelles. Si X et Y sont indépendantes et admettent un moment d'ordre deux, alors* $\operatorname{cov}(X,Y) = 0$.

Démonstration. Soient X et Y deux variables aléatoires discrètes réelles indépendantes et admettant un moment d'ordre deux, c'est-à-dire $E(X^2) < +\infty$ et $E(Y^2) < +\infty$. Par l'inégalité de Cauchy-Schwarz (ou par l'inégalité $|xy| \leq \frac{x^2+y^2}{2}$), on a $E(|XY|) \leq \sqrt{E(X^2)E(Y^2)} < +\infty$, donc XY admet une espérance finie.

L'indépendance de X et Y entraîne (d'après la proposition sur l'espérance d'un produit de variables indépendantes) que $E(XY) = E(X)E(Y)$. Par définition de la covariance,

$$\operatorname{cov}(X,Y) = E(XY) - E(X)E(Y) = E(X)E(Y) - E(X)E(Y) = 0.$$

Ainsi, deux variables aléatoires indépendantes (et admettant des moments d'ordre deux) ont une covariance nulle. □

Proposition 3.17 (Variance de la somme)**.** *Soit X et Y deux variables aléatoires discrètes réelles. Si elles admettent un moment d'ordre deux, alors :*

1. *La variable aléatoire $X+Y$ a un moment d'ordre deux et*

$$V(X+Y) = V(X) + V(Y) + 2\operatorname{cov}(X,Y).$$

2. *Si X et Y sont indépendantes, alors $V(X+Y) = V(X) + V(Y)$.*

Démonstration. Soient X et Y deux variables aléatoires discrètes réelles admettant un moment d'ordre deux, i.e. $E(X^2) < +\infty$ et $E(Y^2) < +\infty$.

1. Montrons d'abord que $X+Y$ admet un moment d'ordre deux. Par l'inégalité $(x+y)^2 \leq 2(x^2+y^2)$, on a
$$E((X+Y)^2) \leq 2\Big(E(X^2) + E(Y^2)\Big) < +\infty,$$
donc $E((X+Y)^2)$ est finie. Calculons la variance de $X+Y$:
$$\begin{aligned} V(X+Y) &= E\Big((X+Y-E(X+Y))^2\Big) \\ &= E\Big((X-E(X)+Y-E(Y))^2\Big) \\ &= E\Big((X-E(X))^2 + (Y-E(Y))^2 + 2(X-E(X))(Y-E(Y))\Big) \\ &= E((X-E(X))^2) + E((Y-E(Y))^2) + 2E\Big((X-E(X))(Y-E(Y))\Big) \\ &= V(X) + V(Y) + 2\operatorname{cov}(X,Y). \end{aligned}$$

2. Si de plus X et Y sont indépendantes, alors d'après la proposition précédente, $\operatorname{cov}(X,Y) = 0$. Par conséquent,
$$V(X+Y) = V(X) + V(Y).$$

□

4 Loi faible des grands nombres

Théorème 4.1 (Loi faible des grands nombres)**.** *Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires réelles deux à deux indépendantes. On suppose que :*

1. *Elles admettent toutes un moment d'ordre deux.*
2. *Elles sont toutes de même loi de probabilités : $\forall (i,j)$, $P_{X_i} = P_{X_j}$.*

On note m l'espérance commune à toutes ces variables aléatoires X_n et $S_n = \sum_{i=1}^n X_i$. Alors :

$$\forall \varepsilon > 0, \quad \lim_{n\to+\infty} P\left(\left|\frac{S_n}{n} - m\right| \geq \varepsilon\right) = 0.$$

On dit que la suite $\left(\frac{S_n}{n}\right)_n$ converge en probabilité vers la variable constante égale à m.

Démonstration. Soit $(X_n)_{n\in\mathbb{N}^*}$ une suite de variables aléatoires réelles deux à deux indépendantes, de même loi, admettant un moment d'ordre deux. Notons $m = E(X_1)$ (espérance commune) et $\sigma^2 = V(X_1)$ (variance commune, finie). On définit $S_n = \sum_{i=1}^n X_i$.

Par linéarité de l'espérance, $E\left(\frac{S_n}{n}\right) = \frac{1}{n}\sum_{i=1}^n E(X_i) = m$.

Comme les X_i sont deux à deux indépendantes, leurs covariances sont nulles (pour $i \neq j$). Par la formule de la variance de la somme,

$$V\left(\frac{S_n}{n}\right) = \frac{1}{n^2}V(S_n) = \frac{1}{n^2}\sum_{i=1}^n V(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Appliquons l'inégalité de Bienaymé-Tchebychev à la variable aléatoire $\frac{S_n}{n}$ (qui admet une espérance m et une variance σ^2/n) :

$$\forall \varepsilon > 0, \quad P\left(\left|\frac{S_n}{n} - m\right| \geq \varepsilon\right) \leq \frac{V\left(\frac{S_n}{n}\right)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Quand $n \to +\infty$, le membre de droite tend vers 0. Par conséquent,

$$\lim_{n\to+\infty} P\left(\left|\frac{S_n}{n} - m\right| \geq \varepsilon\right) = 0.$$

Ceci est exactement la convergence en probabilité de $\frac{S_n}{n}$ vers la constante m. □

5 Fonctions génératrices

Définition 5.1 (Fonction génératrice)**.** *Soit X une variable aléatoire à valeurs dans $\mathbb{N}$. On définit la* ***fonction génératrice*** *G_X de X par :*

$$G_X(t) = E(t^X) = \sum_{k=0}^{+\infty} P([X = k])t^k$$

pour les valeurs réelles de t telles que la variable aléatoire discrète t^X admet une espérance finie.

Remarque 5.2. *Soit X une variable aléatoire à valeurs dans $\mathbb{N}$. On note $p_k = P(X = k)$ pour $k \in \mathbb{N}$. La série génératrice est $G_X(t) = \sum_{k=0}^{+\infty} p_k t^k$.*

1. *Pour $|t| \leq 1$, on a $|p_k t^k| \leq p_k$. La série $\sum p_k$ converge (sa somme vaut 1). Par le théorème de comparaison des séries à termes positifs (ou le critère de majoration), la série $\sum p_k t^k$ converge absolument pour tout t avec $|t| \leq 1$. En particulier, le rayon de convergence R de la série entière vérifie $R \geq 1$.*
2. *Pour $t = 0$, la série se réduit à p_0, donc $G_X(0) = p_0$. La série entière est développable en série entière au voisinage de 0 avec les coefficients p_k. Par conséquent, pour tout $k \in \mathbb{N}$,*

   $$G_X^{(k)}(0) = k!\, p_k = k!\, P(X = k),$$

   d'où $P(X = k) = \dfrac{G_X^{(k)}(0)}{k!}$.
3. *Supposons $R > 1$. Alors la série converge normalement sur tout intervalle $[-a, a]$ avec $a < R$, et en particulier sur un voisinage de 1. On peut donc dériver terme à terme à l'intérieur du disque de convergence. Pour $|t| < R$, on a*

   $$G'_X(t) = \sum_{k=1}^{+\infty} kp_k t^{k-1}, \qquad G''_X(t) = \sum_{k=2}^{+\infty} k(k-1)p_k t^{k-2},$$

   et plus généralement $G_X^{(k)}(t) = \sum_{n=k}^{+\infty} n(n-1)\cdots(n-k+1)p_n t^{n-k}$.
   En prenant $t = 1$, on obtient

   $$G'_X(1) = \sum_{k=1}^{+\infty} kp_k = E(X), \qquad G''_X(1) = \sum_{k=2}^{+\infty} k(k-1)p_k = E\Big(X(X-1)\Big),$$

   et $G_X^{(k)}(1) = E\Big(X(X-1)\cdots(X-k+1)\Big)$.
   Enfin, $V(X) = E(X^2) - E(X)^2 = \Big(E(X(X-1)) + E(X)\Big) - E(X)^2 = G''_X(1) + G'_X(1) - G'_X(1)^2$.

Théorème 5.3. *Soit X une variable aléatoire à valeurs dans $\mathbb{N}$ et G_X sa série génératrice.*

1. *La variable aléatoire X est d'espérance finie si et seulement si G_X est dérivable en 1 ; dans ce cas $E(X) = G'_X(1)$.*
2. *La variable aléatoire X admet un second moment (i.e. $E(X^2) < +\infty$) si et seulement si G_X est deux fois dérivable en 1.*

Démonstration. 1. Pour l'espérance. Si le rayon de convergence R de la série entière définissant G_X est strictement supérieur à 1, le théorème est évident car la série dérivée converge normalement sur un voisinage de 1. Le cas difficile est celui où $R = 1$; en voici la démonstration.

2. Si $R = 1$. Pour $t \in [0, 1[$, on étudie le taux d'accroissement :

$$\Delta(t) = \frac{G_X(1) - G_X(t)}{1-t} = \sum_{n=1}^{+\infty} P(X = n)\frac{1-t^n}{1-t} = \sum_{n=1}^{+\infty} P(X = n)\left(\sum_{k=0}^{n-1} t^k\right).$$

Sens ($\Leftarrow$) **:** Supposons G_X dérivable à gauche en 1. Alors $\lim\limits_{t\to 1^-} \Delta(t) = G'_X(1)$.

Pour tout $N \in \mathbb{N}^*$, par positivité des termes :

$$\forall t \in [0, 1[, \quad \sum_{n=1}^{N} P(X = n)\left(\sum_{k=0}^{n-1} t^k\right) \leq \Delta(t) \leq G'_X(1).$$

En faisant tendre $t \to 1^-$ dans la somme finie, on obtient :

$$\sum_{n=1}^{N} nP(X = n) \leq G'_X(1).$$

La suite des sommes partielles est croissante et majorée par $G'_X(1)$, donc la série converge. X admet une espérance finie et $E(X) \leq G'_X(1)$.

Sens ($\Rightarrow$) **:** Supposons $E(X) < +\infty$.

Pour tout $t \in [0, 1[$ et tout $n \geq 1$, on a $\sum\limits_{k=0}^{n-1} t^k \leq n$. Par sommation :

$$\Delta(t) = \sum_{n=1}^{+\infty} P(X = n)\sum_{k=0}^{n-1} t^k \leq \sum_{n=1}^{+\infty} nP(X = n) = E(X).$$

La fonction Δ est croissante sur $[0, 1[$ et majorée par $E(X)$. D'après le théorème de la limite monotone, $\Delta(t)$ admet une limite finie quand $t \to 1^-$. Ainsi, G_X est dérivable à gauche en 1 et $G'_X(1) \leq E(X)$.

Conclusion : Par double inégalité, $E(X) = G'_X(1)$. □

3. Second Moment et Variance

Le raisonnement est identique pour la dérivée seconde en utilisant le taux d'accroissement de G'_X. On montre que l'existence de $G''_X(1)$ équivaut à la convergence de la série du moment factoriel :

$$G''_X(1) = \sum_{n=2}^{+\infty} n(n-1)P(X = n) = E\Big(X(X-1)\Big).$$

Comme $E(X^2) = E\Big(X(X-1)\Big) + E(X)$, le second moment existe si et seulement si $G''_X(1)$ existe. On en déduit :

$$\boxed{V(X) = G''_X(1) + G'_X(1) - \Big[G'_X(1)\Big]^2}.$$

Proposition 5.4 (Fonction génératrice et somme). *1. Soit X et Y deux variables aléatoires à valeurs dans $\mathbb{N}$ et indépendantes. Alors, pour tout $t \in]-1,1[$:*

$$G_{X+Y}(t) = G_X(t)G_Y(t).$$

2. Soit n variables aléatoires $X_1, \ldots, X_n$ à valeurs dans $\mathbb{N}$ et mutuellement indépendantes. Alors, sur l'intervalle $]-1,1[$:

$$G_{\sum_{i=1}^n X_i} = \prod_{i=1}^n G_{X_i}.$$

Démonstration. 1. Soient X et Y deux variables aléatoires à valeurs dans $\mathbb{N}$ et indépendantes. Pour tout $t \in]-1,1[$, on a :

$$G_{X+Y}(t) = E(t^{X+Y}) = E(t^X t^Y).$$

Par indépendance de X et Y, les variables t^X et t^Y sont indépendantes. L'espérance d'un produit de variables indépendantes est le produit des espérances (car elles sont bornées sur $]-1,1[$). Ainsi,

$$E(t^X t^Y) = E(t^X)E(t^Y) = G_X(t)G_Y(t).$$

Donc $G_{X+Y}(t) = G_X(t)G_Y(t)$ pour tout $t \in]-1,1[$.

2. On procède par récurrence sur n. Pour $n = 1$, l'égalité est triviale. Supposons la propriété vraie au rang $n-1$. Soient $X_1, \ldots, X_n$ mutuellement indépendantes. Alors $\sum_{i=1}^n X_i = \left(\sum_{i=1}^{n-1} X_i\right) + X_n$, où $\sum_{i=1}^{n-1} X_i$ et X_n sont indépendantes (par indépendance mutuelle). En appliquant le point 1 puis l'hypothèse de récurrence,

$$G_{\sum_{i=1}^n X_i}(t) = G_{\sum_{i=1}^{n-1} X_i}(t)\, G_{X_n}(t) = \left(\prod_{i=1}^{n-1} G_{X_i}(t)\right) G_{X_n}(t) = \prod_{i=1}^n G_{X_i}(t).$$

Ceci achève la démonstration.

□

6 Lois usuelles

6.1 Loi binomiale

Définition 6.1 (Loi binomiale). *On dit qu'une variable aléatoire X suit une* ***loi binomiale*** *de paramètres (n,p), lorsque X représente le nombre de succès au cours de n expériences de Bernoulli indépendantes et toutes de paramètre p. On a alors $X(\Omega) = [\![0,n]\!]$ et*

$$P([X=k]) = \binom{n}{k} p^k (1-p)^{n-k}.$$

On la note $X \sim \mathcal{B}(n,p)$.

Proposition 6.2 (Espérance et variance d'une loi binomiale). *Soit $X \sim \mathcal{B}(n,p)$. Alors $E(X) = np$ et $V(X) = np(1-p)$.*

Démonstration. Soit $X \sim \mathcal{B}(n,p)$. On peut représenter X comme la somme de n variables de Bernoulli indépendantes de paramètre p : $X = \sum_{i=1}^n B_i$ où $B_i \sim \mathcal{B}(p)$ et les B_i sont mutuellement indépendantes. Pour chaque i, $E(B_i) = p$ et $V(B_i) = p(1-p)$.

Par linéarité de l'espérance,

$$E(X) = \sum_{i=1}^{n} E(B_i) = np.$$

Par indépendance des B_i, la variance de la somme est la somme des variances :

$$V(X) = \sum_{i=1}^{n} V(B_i) = np(1-p).$$

Ainsi $E(X) = np$ et $V(X) = np(1-p)$. □

6.2 Loi géométrique

Définition 6.3 (Loi géométrique)**.** *On dit que la variable aléatoire X suit une* ***loi géométrique*** *de paramètre $p \in]0,1[$ lorsque :*

1. $X(\Omega) = \mathbb{N}^*$.
2. $P([X = k]) = p(1-p)^{k-1}$ *pour tout entier* $k > 0$.

On note $X \sim \mathcal{G}(p)$ et on pose $q = 1 - p$.

Proposition 6.4 (Espérance et variance d'une loi géométrique)**.** *Soit $X \sim \mathcal{G}(p)$. Alors $E(X) = \dfrac{1}{p}$ et $V(X) = \dfrac{q}{p^2}$.*

Démonstration. Soit $X \sim \mathcal{G}(p)$ (premier succès inclus). On a $P(X = k) = pq^{k-1}$ pour $k \geq 1$, où $q = 1 - p$. Calculons l'espérance :

$$E(X) = \sum_{k=1}^{+\infty} kpq^{k-1} = p \sum_{k=1}^{+\infty} kq^{k-1}.$$

On reconnaît la dérivée de la série géométrique : $\sum_{k=1}^{+\infty} kq^{k-1} = \frac{1}{(1-q)^2} = \frac{1}{p^2}$. Donc $E(X) = p \cdot \frac{1}{p^2} = \frac{1}{p}$.

Pour la variance, calculons d'abord $E(X^2) = \sum_{k=1}^{+\infty} k^2 pq^{k-1}$. On utilise $k^2 = k(k-1) + k$. Ainsi,

$$E(X^2) = \sum_{k=1}^{+\infty} k(k-1)pq^{k-1} + \sum_{k=1}^{+\infty} kpq^{k-1} = pq \sum_{k=2}^{+\infty} k(k-1)q^{k-2} + E(X).$$

Or $\sum_{k=2}^{+\infty} k(k-1)q^{k-2} = \frac{2}{(1-q)^3} = \frac{2}{p^3}$. Donc $pq \cdot \frac{2}{p^3} = \frac{2q}{p^2}$. Par conséquent,

$$E(X^2) = \frac{2q}{p^2} + \frac{1}{p}.$$

La variance est $V(X) = E(X^2) - E(X)^2 = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{2q}{p^2} + \frac{p}{p^2} - \frac{1}{p^2} = \frac{2q+p-1}{p^2} = \frac{2(1-p)+p-1}{p^2} = \frac{2-2p+p-1}{p^2} = \frac{1-p}{p^2} = \frac{q}{p^2}$. □

6.3 Loi géométrique et absence de mémoire

Proposition 6.5. *Soit X une variable aléatoire suivant une loi géométrique de paramètre $p \in]0,1[$, c'est-à-dire :*

$$\forall k \in \mathbb{N}^*, \quad P(X = k) = p(1-p)^{k-1}.$$

*Alors X vérifie la propriété d'****absence de mémoire*** *:*

$$\forall n, m \in \mathbb{N}^*, \quad P(X > n + m \mid X > n) = P(X > m).$$

Démonstration. Commençons par calculer $P(X > n)$ pour $n \in \mathbb{N}^*$:

$$P(X > n) = \sum_{k=n+1}^{+\infty} p(1-p)^{k-1} = p(1-p)^n \sum_{k=0}^{+\infty} (1-p)^k = p(1-p)^n \cdot \frac{1}{1-(1-p)} = (1-p)^n.$$

On a également $P(X > n+m) = (1-p)^{n+m}$.
Par définition de la probabilité conditionnelle :

$$P(X > n{+}m \mid X > n) = \frac{P\Big((X > n+m) \cap (X > n)\Big)}{P(X > n)} = \frac{P(X > n+m)}{P(X > n)} = \frac{(1-p)^{n+m}}{(1-p)^n} = (1{-}p)^m.$$

Or $P(X > m) = (1-p)^m$. On obtient donc l'égalité annoncée :

$$P(X > n+m \mid X > n) = P(X > m).$$

□

Remarque 6.6. *Cette propriété se traduit par : la probabilité qu'il faille attendre encore m épreuves avant d'obtenir un succès, sachant qu'aucun succès n'est apparu lors des n premières épreuves, est la même que la probabilité d'attendre m épreuves à partir du début. La loi géométrique est la* ***seule*** *loi de probabilité discrète sur $\mathbb{N}^*$ à vérifier cette propriété.*

6.4 Loi de Poisson

Définition 6.7 (Loi de Poisson)**.** *On dit qu'une variable aléatoire X suit la* ***loi de Poisson*** *de paramètre $\lambda > 0$ lorsque :*

1. $X(\Omega) = \mathbb{N}$.
2. $P([X = k]) = e^{-\lambda}\dfrac{\lambda^k}{k!}$ *pour tout entier k.*

On note $X \sim \mathcal{P}(\lambda)$.

Proposition 6.8 (Espérance et variance d'une loi de Poisson)**.** *Soit X une variable aléatoire qui suit la loi de Poisson $\mathcal{P}(\lambda)$. Alors $E(X) = \lambda$ et $V(X) = \lambda$.*

Démonstration. Soit $X \sim \mathcal{P}(\lambda)$, c'est-à-dire $P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}$ pour $k \in \mathbb{N}$. Calculons l'espérance :

$$E(X) = \sum_{k=0}^{+\infty} k\, e^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}\sum_{k=1}^{+\infty}\frac{\lambda^k}{(k-1)!} = e^{-\lambda}\lambda\sum_{j=0}^{+\infty}\frac{\lambda^j}{j!} = e^{-\lambda}\lambda e^{\lambda} = \lambda.$$

Pour la variance, calculons $E(X(X-1))$:

$$E(X(X-1)) = \sum_{k=0}^{+\infty} k(k-1)\, e^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}\sum_{k=2}^{+\infty}\frac{\lambda^k}{(k-2)!} = e^{-\lambda}\lambda^2\sum_{j=0}^{+\infty}\frac{\lambda^j}{j!} = e^{-\lambda}\lambda^2 e^{\lambda} = \lambda^2.$$

Ainsi $E(X^2) = E(X(X-1)) + E(X) = \lambda^2 + \lambda$. Par conséquent,

$$V(X) = E(X^2) - E(X)^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda.$$

□

Proposition 6.9 (Approximation d'une limite de loi binomiale par une loi de Poisson)**.** *Soit $(X_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires telle que pour tout n, X_n suit une loi binomiale de paramètres (n, p_n) : $X_n \sim \mathcal{B}(n, p_n)$. On suppose que lorsque n tend vers l'infini le produit $n \cdot p_n$ des paramètres tend vers une limite $\lambda > 0$. Alors :*

$$\forall k \in \mathbb{N}, \quad \lim_{n\to+\infty} P(X_n = k) = e^{-\lambda}\frac{\lambda^k}{k!}.$$

Démonstration. Soit $X_n \sim \mathcal{B}(n, p_n)$ avec $p_n \in]0,1[$. On suppose que $\lim_{n\to+\infty} np_n = \lambda > 0$. On note $q_n = 1 - p_n$. Pour tout $k \in \mathbb{N}$ fixé, on a :

$$P(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

Pour n suffisamment grand (dès que $n \geq k$), on peut écrire :

$$P(X_n = k) = \frac{n(n-1)\cdots(n-k+1)}{k!}\, p_n^k\,(1-p_n)^{n-k}.$$

On factorise n^k :

$$P(X_n = k) = \frac{n^k}{k!}\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{k-1}{n}\right) p_n^k\,(1-p_n)^n\,(1-p_n)^{-k}.$$

Posons $\lambda_n = np_n$. Alors $p_n = \lambda_n/n$. Ainsi,

$$P(X_n = k) = \frac{\lambda_n^k}{k!}\left(1-\frac{1}{n}\right)\cdots\left(1-\frac{k-1}{n}\right)(1-p_n)^n\,(1-p_n)^{-k}.$$

Quand $n \to +\infty$:

- $\lambda_n \to \lambda$,
- $\left(1-\frac{j}{n}\right) \to 1$ pour chaque j fixé,
- $(1-p_n)^{-k} \to 1$ car $p_n \to 0$,
- $(1-p_n)^n = \left(1-\frac{\lambda_n}{n}\right)^n \to e^{-\lambda}$ (limite classique).

Par conséquent,

$$\lim_{n\to+\infty} P(X_n = k) = \frac{\lambda^k}{k!}\cdot 1 \cdot e^{-\lambda}\cdot 1 = e^{-\lambda}\frac{\lambda^k}{k!}.$$

□

Proposition 6.10 (Somme de deux Poisson indépendantes)**.** *Soit X et Y deux variables aléatoires indépendantes suivant des lois de Poisson de paramètres respectifs λ et μ. Alors $X+Y$ suit une loi de Poisson de paramètre $\lambda+\mu$.*

Proposition 6.11 (Somme de deux Poisson indépendantes)**.** *Soit X et Y deux variables aléatoires indépendantes suivant des lois de Poisson de paramètres respectifs λ et μ. Alors $X+Y$ suit une loi de Poisson de paramètre $\lambda+\mu$.*

Démonstration. Pour tout $k \in \mathbb{N}$, calculons $P(X+Y=k)$ en utilisant le système complet d'événements $(X=i)_{i\in\mathbb{N}}$:

$$P(X+Y=k) = \sum_{i=0}^{k} P(X=i \text{ et } Y=k-i).$$

Par indépendance de X et Y :

$$P(X+Y=k) = \sum_{i=0}^{k} P(X=i)\,P(Y=k-i).$$

En utilisant les expressions des lois de Poisson :

$$P(X=i) = e^{-\lambda}\frac{\lambda^i}{i!}, \qquad P(Y=k-i) = e^{-\mu}\frac{\mu^{k-i}}{(k-i)!}.$$

On obtient :

$$P(X+Y=k) = e^{-(\lambda+\mu)} \sum_{i=0}^{k} \frac{\lambda^i}{i!} \cdot \frac{\mu^{k-i}}{(k-i)!} = e^{-(\lambda+\mu)} \frac{1}{k!} \sum_{i=0}^{k} \frac{k!}{i!(k-i)!} \lambda^i \mu^{k-i}.$$

Reconnaissons le coefficient binomial $\binom{k}{i} = \frac{k!}{i!(k-i)!}$ et la formule du binôme de Newton :

$$\sum_{i=0}^{k} \binom{k}{i} \lambda^i \mu^{k-i} = (\lambda+\mu)^k.$$

Ainsi :

$$P(X+Y=k) = e^{-(\lambda+\mu)} \frac{(\lambda+\mu)^k}{k!}.$$

C'est précisément la loi de Poisson de paramètre $\lambda+\mu$. □

Corollaire 6.12 (Généralisation à n variables)**.** *Soit $X_1, X_2, \ldots, X_n$ n variables aléatoires mutuellement indépendantes. On suppose que pour tout $i \in \{1, \ldots, n\}$, X_i suit une loi de Poisson de paramètre $\lambda_i > 0$. Alors la somme*

$$S_n = X_1 + X_2 + \cdots + X_n$$

suit une loi de Poisson de paramètre $\Lambda = \lambda_1 + \lambda_2 + \cdots + \lambda_n$.

Démonstration par récurrence. Pour $n = 1$, le résultat est trivial. Supposons la propriété vraie au rang $n-1$. Alors $S_{n-1} = X_1 + \cdots + X_{n-1}$ suit une loi de Poisson de paramètre $\lambda_1 + \cdots + \lambda_{n-1}$, et S_{n-1} est indépendante de X_n (car les X_i sont mutuellement indépendantes). En appliquant la proposition à S_{n-1} et X_n, on obtient que $S_n = S_{n-1} + X_n$ suit une loi de Poisson de paramètre $(\lambda_1 + \cdots + \lambda_{n-1}) + \lambda_n = \Lambda$. La propriété est donc héréditaire. □

Remarque 6.13. *Cette propriété de stabilité par convolution est caractéristique de la loi de Poisson. Elle est notamment utilisée pour modéliser le nombre total d'événements rares survenant dans des contextes indépendants.*

Deuxième démonstration par les fonctions génératrices. Les fonctions génératrices de X et Y sont respectivement $G_X(t) = e^{\lambda(t-1)}$ et $G_Y(t) = e^{\mu(t-1)}$ pour tout $t \in \mathbb{R}$. Par indépendance, la fonction génératrice de la somme $S = X + Y$ est le produit :

$$G_S(t) = G_X(t) G_Y(t) = e^{\lambda(t-1)} e^{\mu(t-1)} = e^{(\lambda+\mu)(t-1)}.$$

Or cette expression est précisément la fonction génératrice d'une variable aléatoire suivant la loi de Poisson de paramètre $\lambda+\mu$. Comme la fonction génératrice caractérise la loi (sur $\mathbb{N}$), on en déduit $S \sim \mathcal{P}(\lambda+\mu)$. □

7 Exercices corrigés : Fonctions génératrices et applications

Exercice 1 (Retour sur les lois usuelles)**.** *À l'aide des fonctions génératrices, retrouver l'espérance et la variance des cinq lois suivantes :*

a) Loi de Bernoulli $\mathcal{B}(p)$

b) Loi binomiale $\mathcal{B}(n, p)$

c) Loi géométrique $\mathcal{G}(p)$ (support $\mathbb{N}^*$)

d) Loi de Poisson $\mathcal{P}(\lambda)$

Corrigé. *Rappelons que pour une variable aléatoire X à valeurs dans $\mathbb{N}$, la fonction génératrice est $G_X(t) = E(t^X) = \sum_{k\geq 0} P(X = k)t^k$.*

On a alors $E(X) = G'_X(1)$ et $V(X) = G''_X(1) + G'_X(1) - G'_X(1)^2$.

a) ***Loi de Bernoulli*** *$\mathcal{B}(p)$* ***:*** *$X(\Omega) = \{0, 1\}$, $P(X = 0) = 1 - p$, $P(X = 1) = p$.*

$$G_X(t) = (1 - p) + pt.$$

Alors $G'_X(t) = p$, donc $E(X) = G'_X(1) = p$. $G''_X(t) = 0$, donc $V(X) = 0+p-p^2 = p(1-p)$.

b) ***Loi binomiale*** *$\mathcal{B}(n, p)$* ***:*** *$X = \sum_{i=1}^n X_i$ avec $X_i \sim \mathcal{B}(p)$ indépendantes. Par indépendance, $G_X(t) = (G_{X_1}(t))^n = ((1 - p) + pt)^n$.*

$$G'_X(t) = n((1 - p) + pt)^{n-1} \cdot p, \quad G'_X(1) = n \cdot 1^{n-1} \cdot p = np.$$

$$G''_X(t) = n(n - 1)p^2((1 - p) + pt)^{n-2}, \quad G''_X(1) = n(n - 1)p^2.$$

Ainsi $V(X) = n(n - 1)p^2 + np - (np)^2 = np(1 - p)$.

c) ***Loi géométrique*** *$\mathcal{G}(p)$* ***(support*** *$\mathbb{N}^*$****) :*** *$P(X = k) = (1 - p)^{k-1}p$ pour $k \geq 1$.*

$$G_X(t) = \sum_{k=1}^{+\infty}(1 - p)^{k-1}pt^k = pt\sum_{k=0}^{+\infty}((1 - p)t)^k = \frac{pt}{1 - (1 - p)t}, \quad \text{pour } |t| < \frac{1}{1 - p}.$$

$$G'_X(t) = \frac{p(1 - (1 - p)t) - pt(-(1 - p))}{(1 - (1 - p)t)^2} = \frac{p}{(1 - (1 - p)t)^2}, \quad G'_X(1) = \frac{p}{(1 - (1 - p))^2} = \frac{1}{p}.$$

$$G''_X(t) = \frac{2p(1 - p)}{(1 - (1 - p)t)^3}, \quad G''_X(1) = \frac{2(1 - p)}{p^2}.$$

Donc $V(X) = \frac{2(1-p)}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{2-2p+p-1}{p^2} = \frac{1-p}{p^2}$.

d) ***Loi de Poisson*** *$\mathcal{P}(\lambda)$* ***:*** *$P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}$.*

$$G_X(t) = e^{-\lambda}\sum_{k=0}^{+\infty}\frac{(\lambda t)^k}{k!} = e^{-\lambda}e^{\lambda t} = e^{\lambda(t-1)}.$$

$G'_X(t) = \lambda e^{\lambda(t-1)}$, donc $E(X) = \lambda$. $G''_X(t) = \lambda^2 e^{\lambda(t-1)}$, donc $E(X(X - 1)) = \lambda^2$ et $V(X) = \lambda^2 + \lambda - \lambda^2 = \lambda$.

Exercice 2 (Théorème de Weierstrass)**.** *Soit $f : [0, 1] \to \mathbb{R}$ une fonction continue. On définit le polynôme de Bernstein de degré n par :*

$$B_n(f)(x) = \sum_{k=0}^{n} f\left(\frac{k}{n}\right)\binom{n}{k}x^k(1 - x)^{n-k}.$$

a) Interpréter $B_n(f)(x)$ comme l'espérance d'une certaine variable aléatoire.

b) En utilisant la loi faible des grands nombres, démontrer que $B_n(f)$ converge uniformément vers f sur $[0, 1]$.

Corrigé. *a) Soit $x \in [0, 1]$ fixé. Considérons une variable aléatoire $S_n \sim \mathcal{B}(n, x)$ (loi binomiale de paramètres n et x). Alors :*

$$E\left(f\left(\frac{S_n}{n}\right)\right) = \sum_{k=0}^{n} f\left(\frac{k}{n}\right)P(S_n = k) = \sum_{k=0}^{n} f\left(\frac{k}{n}\right)\binom{n}{k}x^k(1 - x)^{n-k} = B_n(f)(x).$$

Ainsi $B_n(f)(x)$ est l'espérance de $f(S_n/n)$ où $S_n \sim \mathcal{B}(n, x)$.

b) *La loi faible des grands nombres (LFDGN) s'applique à la suite de variables de Bernoulli indépendantes* $X_i \sim \mathcal{B}(x)$. *On a* $S_n = X_1 + \cdots + X_n$ *et* $\frac{S_n}{n} \to x$ *en probabilité. Par continuité de* f, $\frac{S_n}{n}$ *converge en probabilité vers* x, *donc* $f(S_n/n)$ *converge en probabilité vers* $f(x)$.
Comme f *est continue sur le compact* $[0,1]$, *elle est bornée :* $\|f\|_\infty < +\infty$. *L'inégalité de Bienaymé-Tchebychev donne :*

$$P\left(\left|\frac{S_n}{n} - x\right| \geq \delta\right) \leq \frac{x(1-x)}{n\delta^2} \leq \frac{1}{4n\delta^2}.$$

Pour tout $\varepsilon > 0$, *choisissons* $\delta > 0$ *tel que* $|x-y| \leq \delta \Rightarrow |f(x) - f(y)| \leq \varepsilon$ *(continuité uniforme de* f *sur* $[0,1]$*). Alors :*

$$|B_n(f)(x) - f(x)| = \left|E\left(f\left(\frac{S_n}{n}\right) - f(x)\right)\right| \leq E\left(\left|f\left(\frac{S_n}{n}\right) - f(x)\right|\right).$$

En séparant les cas $\left|\frac{S_n}{n} - x\right| \leq \delta$ *et* $> \delta$ *:*

$$|B_n(f)(x) - f(x)| \leq \varepsilon + 2\|f\|_\infty P\left(\left|\frac{S_n}{n} - x\right| \geq \delta\right) \leq \varepsilon + \frac{\|f\|_\infty}{2n\delta^2}.$$

Pour n *suffisamment grand,* $\frac{\|f\|_\infty}{2n\delta^2} \leq \varepsilon$, *d'où* $|B_n(f)(x) - f(x)| \leq 2\varepsilon$, *uniformément en* x. *Ainsi* $B_n(f) \to f$ *uniformément sur* $[0,1]$.

Exercice 3 (Processus de Galton-Watson)**.** *Soit* $(Z_n)_{n\geq 0}$ *un processus de Galton-Watson, défini par* $Z_0 = 1$ *et pour* $n \geq 0$ *:*

$$Z_{n+1} = \sum_{i=1}^{Z_n} X_{n,i},$$

où $(X_{n,i})_{n,i\geq 1}$ *sont des variables aléatoires i.i.d. à valeurs dans* $\mathbb{N}$, *de loi commune* μ, *d'espérance* $m = E(X_{1,1})$ *et de fonction génératrice* $G(s) = E(s^{X_{1,1}})$.

a) *Montrer que la fonction génératrice* $G_n(s) = E(s^{Z_n})$ *vérifie* $G_{n+1}(s) = G_n(G(s)) = G(G_n(s))$.
b) *En déduire l'expression de* $E(Z_n)$ *et* $V(Z_n)$ *en fonction de* m *et de* $\sigma^2 = V(X_{1,1})$.
c) *Donner la condition de survie du processus (extinction presque sûre vs risque de croissance exponentielle).*

Corrigé. a) *Par définition,* $Z_{n+1} = \sum_{i=1}^{Z_n} X_{n,i}$. *En conditionnant par* Z_n *:*

$$G_{n+1}(s) = E(s^{Z_{n+1}}) = E\left(E(s^{Z_{n+1}} \mid Z_n)\right) = E\left((E(s^{X_{1,1}}))^{Z_n}\right) = E(G(s)^{Z_n}) = G_n(G(s)).$$

Avec $G_0(s) = s$, *on a* $G_1(s) = G(s)$, *puis par récurrence* $G_n(s) = G(G_{n-1}(s))$.

b) *Dérivons la relation* $G_{n+1}(s) = G_n(G(s))$ *:*

$$G'_{n+1}(s) = G'_n(G(s)) \cdot G'(s).$$

En $s = 1$, $G(1) = 1$, $G'(1) = m$, $G'_n(1) = E(Z_n)$. *On obtient :*

$$E(Z_{n+1}) = E(Z_n) \cdot m.$$

Avec $E(Z_0) = 1$, *on a* $E(Z_n) = m^n$.
Pour la variance, dérivons une seconde fois :

$$G''_{n+1}(s) = G''_n(G(s)) \cdot G'(s)^2 + G'_n(G(s)) \cdot G''(s).$$

En $s = 1$: $E(Z_{n+1}(Z_{n+1}-1)) = E(Z_n(Z_n-1))\cdot m^2 + E(Z_n)\cdot G''(1)$. Posons $V_n = V(Z_n) = E(Z_n^2) - E(Z_n)^2 = E(Z_n(Z_n-1)) + E(Z_n) - E(Z_n)^2$. Avec $G''(1) = E(X(X-1)) = \sigma^2 + m^2 - m$, on obtient par récurrence :

$$V(Z_n) = \begin{cases} n\sigma^2 & \text{si } m = 1, \\ \sigma^2 \dfrac{m^n(m^n-1)}{m^2-m} & \text{si } m \neq 1. \end{cases}$$

c) *La probabilité d'extinction $\eta = P(\exists n, Z_n = 0)$ est la plus petite solution dans $[0,1]$ de l'équation $G(s) = s$. Le comportement dépend de $m = G'(1)$:*
   - *Si $m \leq 1$ et $G(s) \neq s$ pour $s \in [0,1[$, alors $\eta = 1$ (extinction presque sûre).*
   - *Si $m > 1$, alors $\eta < 1$ (le processus a une probabilité non nulle de croître exponentiellement).*

   La valeur $m = 1$ est le cas critique : l'extinction est presque sûre mais le temps d'extinction a une espérance infinie.

Exercice 4. *Fonction génératrice des moments (loi de Poisson) Soit X une variable aléatoire suivant la loi de Poisson de paramètre $\lambda > 0$: $P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}$ pour $k \in \mathbb{N}$.*

(a) *Déterminer la fonction génératrice des moments $M_X(t) = E(e^{tX})$ et préciser son domaine de définition.*

(b) *En déduire $E(X)$, $E(X^2)$ et $V(X)$.*

Corrigé. (a) $M_X(t) = E(e^{tX}) = \sum_{k=0}^{+\infty} e^{tk} e^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}\sum_{k=0}^{+\infty}\frac{(\lambda e^t)^k}{k!} = e^{-\lambda}e^{\lambda e^t} = e^{\lambda(e^t-1)}$. *La série converge pour tout $t \in \mathbb{R}$ car c'est une exponentielle. Donc $M_X(t)$ est définie sur $\mathbb{R}$.*

(b) *On calcule les dérivées : $M_X'(t) = e^{\lambda(e^t-1)}\cdot\lambda e^t = \lambda e^t M_X(t)$. En $t = 0$, $M_X(0) = 1$, donc $E(X) = M_X'(0) = \lambda$. $M_X''(t) = \lambda e^t M_X(t) + \lambda e^t M_X'(t) = \lambda e^t M_X(t)(1+\lambda e^t)$. En $t = 0$, $M_X''(0) = \lambda(1+\lambda) = \lambda + \lambda^2$. Ainsi $E(X^2) = M_X''(0) = \lambda + \lambda^2$, et $V(X) = E(X^2) - E(X)^2 = \lambda$.*

Exercice 5. *Fonction caractéristique (loi binomiale) Soit X une variable aléatoire suivant la loi binomiale $\mathcal{B}(n,p)$ avec $n \in \mathbb{N}^*$ et $p \in]0,1[$.*

(a) *Déterminer la fonction caractéristique $\phi_X(t) = E(e^{itX})$ pour $t \in \mathbb{R}$.*

(b) *En déduire $E(X)$ et $V(X)$.*

Corrigé. (a) ***Fonction caractéristique.*** *Par définition, la fonction caractéristique de $X \sim \mathcal{B}(n,p)$ est :*

$$\phi_X(t) = E(e^{itX}) = \sum_{k=0}^{n} e^{itk}P(X = k) = \sum_{k=0}^{n} e^{itk}\binom{n}{k}p^k(1-p)^{n-k}.$$

On factorise l'expression :

$$\phi_X(t) = \sum_{k=0}^{n}\binom{n}{k}(pe^{it})^k(1-p)^{n-k}.$$

On reconnaît la formule du binôme de Newton : $\sum_{k=0}^{n}\binom{n}{k}a^k b^{n-k} = (a+b)^n$. Ici $a = pe^{it}$ et $b = 1-p$. On obtient donc :

$$\phi_X(t) = (1 - p + pe^{it})^n.$$

(b) ***Espérance.*** *Les moments se déduisent des dérivées de ϕ_X en 0 :*

$$E(X) = \frac{1}{i}\phi'_X(0), \qquad E(X^2) = -\phi''_X(0).$$

Calculons la dérivée première de ϕ_X :

$$\phi_X(t) = (1 - p + pe^{it})^n.$$

En posant $u(t) = 1 - p + pe^{it}$, on a $\phi_X = u^n$, donc $\phi'_X = nu^{n-1}u'$. Or $u'(t) = p \cdot ie^{it}$. Ainsi :

$$\phi'_X(t) = n(1 - p + pe^{it})^{n-1} \cdot ipe^{it}.$$

Évaluons en $t = 0$: $e^{i\cdot 0} = 1$, donc $1 - p + p \cdot 1 = 1$. Par conséquent :

$$\phi'_X(0) = n \cdot 1^{n-1} \cdot ip \cdot 1 = inp.$$

On en déduit l'espérance :

$$E(X) = \frac{1}{i}\phi'_X(0) = \frac{1}{i} \cdot inp = np.$$

(c) ***Second moment.*** *Calculons la dérivée seconde de ϕ_X. On dérive $\phi'_X(t) = nipe^{it}(1-p + pe^{it})^{n-1}$.*
C'est un produit de deux fonctions : $f(t) = nipe^{it}$ et $g(t) = (1 - p + pe^{it})^{n-1}$. On a $f'(t) = nip \cdot ie^{it} = -npe^{it}$ (car $i^2 = -1$). Et $g'(t) = (n - 1)(1 - p + pe^{it})^{n-2} \cdot ipe^{it}$.
La dérivée seconde est donc :

$$\phi''_X(t) = f'(t)g(t) + f(t)g'(t).$$

Soit :

$$\phi''_X(t) = (-npe^{it})(1 - p + pe^{it})^{n-1} + (nipe^{it}) \cdot (n - 1)(1 - p + pe^{it})^{n-2} \cdot ipe^{it}.$$

Simplifions le second terme : $(nipe^{it}) \cdot (n - 1) \cdot (ipe^{it}) = n(n - 1)i^2p^2e^{2it} = -n(n - 1)p^2e^{2it}$ (car $i^2 = -1$).
Ainsi :

$$\phi''_X(t) = -npe^{it}(1 - p + pe^{it})^{n-1} - n(n - 1)p^2e^{2it}(1 - p + pe^{it})^{n-2}.$$

Évaluons en $t = 0$: $e^{i\cdot 0} = 1$, $1 - p + p = 1$. Donc :

$$\phi''_X(0) = -np \cdot 1^{n-1} - n(n - 1)p^2 \cdot 1^{n-2} = -np - n(n - 1)p^2.$$

On en déduit le second moment :

$$E(X^2) = -\phi''_X(0) = np + n(n - 1)p^2.$$

(d) ***Variance.*** *Par la formule de König-Huygens :*

$$V(X) = E(X^2) - E(X)^2 = \left[np + n(n - 1)p^2\right] - (np)^2.$$

Développons $(np)^2 = n^2p^2$. Alors :

$$V(X) = np + n(n - 1)p^2 - n^2p^2 = np + \left(n^2p^2 - np^2\right) - n^2p^2 = np - np^2 = np(1 - p).$$

On retrouve bien la formule classique $V(X) = np(1 - p)$.